IBM Developer
SKILLS NETWORK

Winning Space Race with Data Science

Nome: Leonardo Henrique Ramos Ferreira
23/02/2026

Roteiro

- Resumo Executivo
- Introducao
- Metodologia
- Resultados
- Conclusao

Resumo Executivo

Metodologias Utilizadas

1.Aquisição de Dados: Obtivemos informações dos lançamentos da SpaceX por meio de API e complementamos com registros coletados da Wikipédia.

2.Tratamento e Organização dos Dados:

- Realizamos limpeza e padronização das informações.
- Armazenamos os dados em um banco Db2 e aplicamos consultas SQL.
- Fizemos análises exploratórias para entender padrões iniciais.

3.Criação de Variáveis (Feature Engineering): Desenvolvemos novos atributos e normalizamos os dados para melhorar a qualidade da análise.

4.Visualizações Dinâmicas:

- Produzimos mapas interativos dos locais de lançamento e suas taxas de sucesso utilizando Folium.

5.Modelagem e Avaliação:

- Testamos algoritmos como SVM, Árvores de Decisão e KNN.
- Ajustamos parâmetros com GridSearchCV.
- Validamos os modelos com dados de teste, medindo a acurácia.
- Criamos um painel interativo com Plotly Dash para explorar os resultados.

Principais Resultados

1.Análises dos Dados:

- Identificamos variáveis que afetam diretamente os pousos do Falcon 9.
- Observamos padrões geográficos relacionados ao desempenho.

2.Performance dos Modelos:

- SVM e KNN alcançaram cerca de 83% de acurácia.
- Árvores de Decisão chegaram a aproximadamente 95% de acurácia.

3.Conclusões Relevantes:

- O local de lançamento e a massa da carga útil são fatores decisivos para o sucesso.
- O modelo de Árvores de Decisão se mostrou o mais confiável.
- Criamos um painel interativo com Plotly Dash para explorar os resultados.

Introdução

Contexto e objetivo do projeto:

Neste capstone, buscamos construir uma solução capaz de estimar se o primeiro estágio do Falcon 9 terá pouso bem-sucedido. A SpaceX se diferencia por reduzir custos ao reutilizar o primeiro estágio, o que impacta diretamente o preço final de cada missão. Com uma boa previsão de pouso, é possível inferir melhor os custos envolvidos e gerar informações úteis para organizações que precisam comparar/competir com a SpaceX em propostas e contratos.

Perguntas que guiam a análise:

- Quais variáveis estão mais associadas ao sucesso de pouso do primeiro estágio do Falcon 9?
- De que forma modelos de aprendizado de máquina podem ser aplicados para prever o resultado do pouso com boa precisão?
- Entre os modelos testados, qual apresenta o melhor desempenho na previsão de sucesso?

Seção 1

Methodology

Metodologia

Metodologia

1.Visão Geral: O projeto segue uma abordagem completa para prever o sucesso dos pousos do Falcon 9, englobando coleta de dados, preparação, análise exploratória, visualizações e modelagem preditiva.

2. Aquisição de Dados: As informações foram obtidas diretamente da API da SpaceX, contendo detalhes sobre datas de lançamento, locais, cargas transportadas e resultados.

3. Preparação e Organização dos Dados:

- Tratamos valores ausentes e inconsistências.
- Padronizamos os formatos para manter uniformidade.
- Extraímos variáveis importantes e criamos novos atributos para enriquecer o dataset.

4. Exploração dos Dados (EDA):

- Utilizamos Matplotlib e Seaborn para visualizar taxas de sucesso, cargas úteis e locais de lançamento.
- Aplicamos consultas SQL para obter insights e responder questões específicas sobre os registros.

Metodologia

Visualizações Interativas:

- Criamos mapas dinâmicos com Folium para mostrar os locais de lançamento e seus respectivos resultados.
- Desenvolvemos um painel em Plotly Dash com recursos interativos, como filtros e controles deslizantes, permitindo analisar taxas de sucesso e diferentes faixas de carga útil.

Modelagem Preditiva:

- Testamos e avaliamos vários algoritmos de classificação, incluindo Regressão Logística, SVM, KNN e Árvores de Decisão.
- Utilizamos GridSearchCV para ajustar os parâmetros e melhorar o desempenho dos modelos.
- A acurácia foi usada como métrica principal, e identificamos qual modelo se destacou na previsão dos pousos bem-sucedidos.

Github URL: https://github.com/leoh-coder/IBM-Applied-Data-Science-Capstone

Coleta de dados – API SpaceX

Etapa 1: Requisição à API da SpaceX

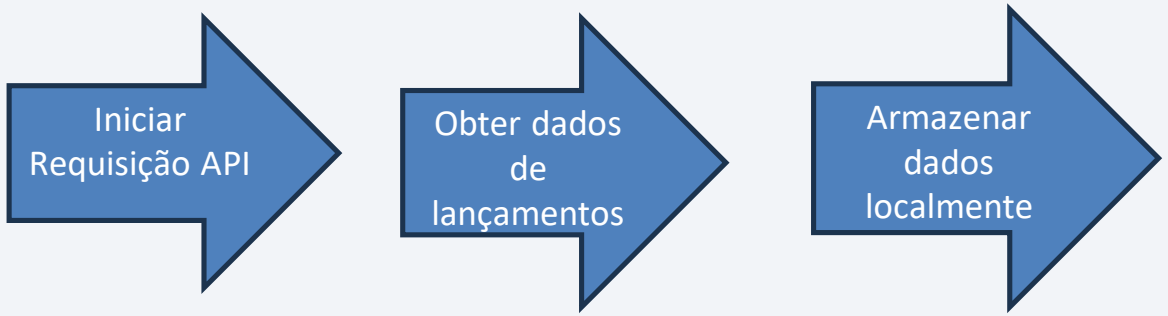

Etapa 2: Web Scraping da Wikipédia

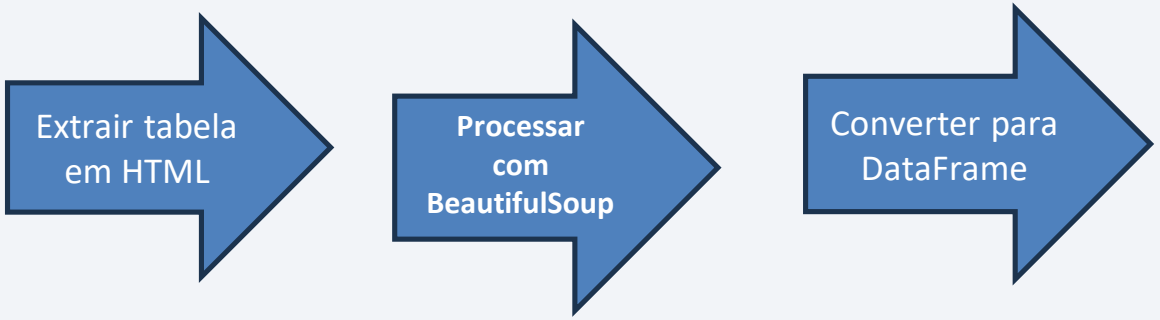

Etapa 3: Integração dos Dados

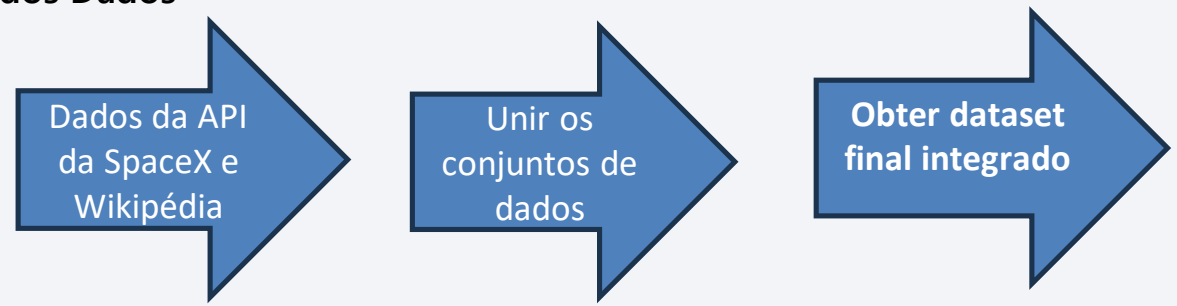

Coleta de Dados – API da SpaceX

Etapa 1: Iniciar Requisição à API

- Usar a biblioteca requests do Python para conectar à API da SpaceX.
- Endpoint: https://api.spacexdata.com/v4/launches

Etapa 2: Processar Resposta da API

- Converter a resposta da API de JSON para um dicionário Python.
- Extrair campos relevantes: data do lançamento, local, massa da carga útil, tipo de foguete, resultado.

Etapa 3: Armazenar Dados Localmente

- Salvar os dados extraídos em um DataFrame do pandas.
- Armazenar o DataFrame localmente para processamento posterior.

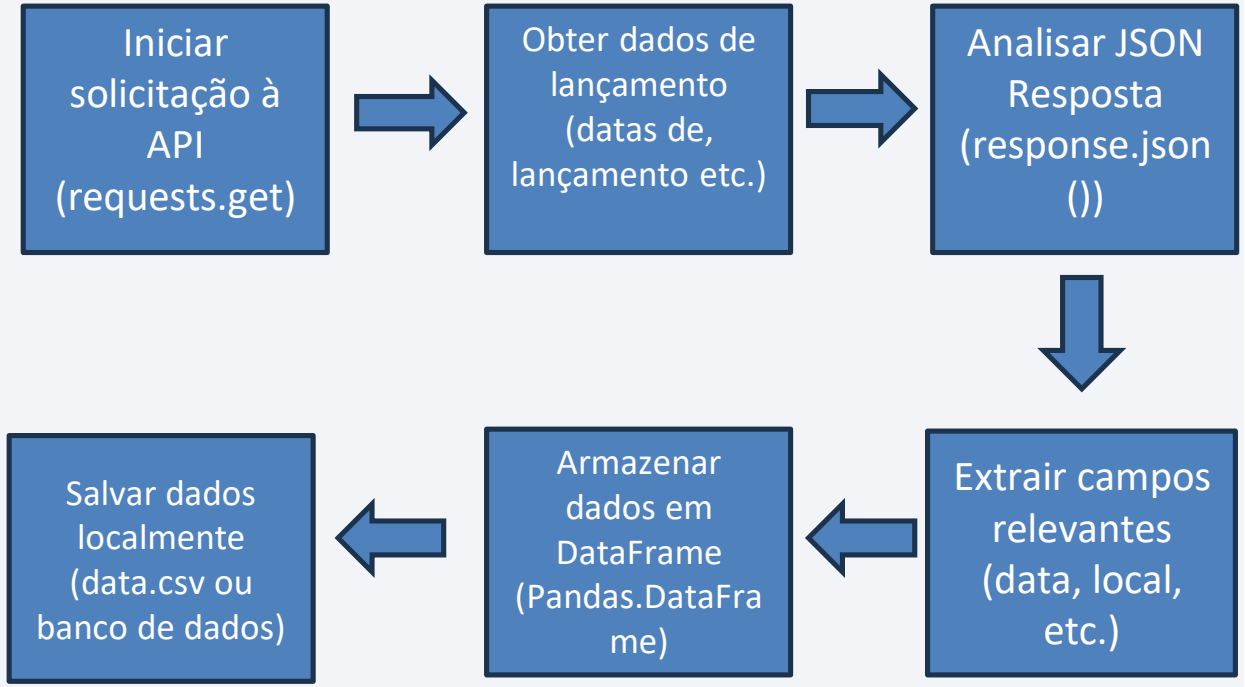

Coleta de Dados - Scraping

Etapa 1: Iniciar Web Scraping

- Usar a biblioteca requests do Python para buscar o conteúdo HTML da página da Wikipédia.

- URL alvo: https://en.wikipedia.org/wiki/List_of_Falcon_9_and_Falcon_Heavy_launches

Etapa 2: Interpretar o conteúdo HTML

- Use BeautifulSoup para analisar (Parsear) o HTML.

- Extrair a tabela HTML que contém os registros de lançamentos do Falcon 9.

Etapa 3: Converter para DataFrame

- Converta a tabela HTML extraída para um DataFrame do pandas.

- Limpe e formate o DataFrame, garantindo consistência dos dados.

URL do GitHub: 2.jupyter-labs-webscraping.ipynb

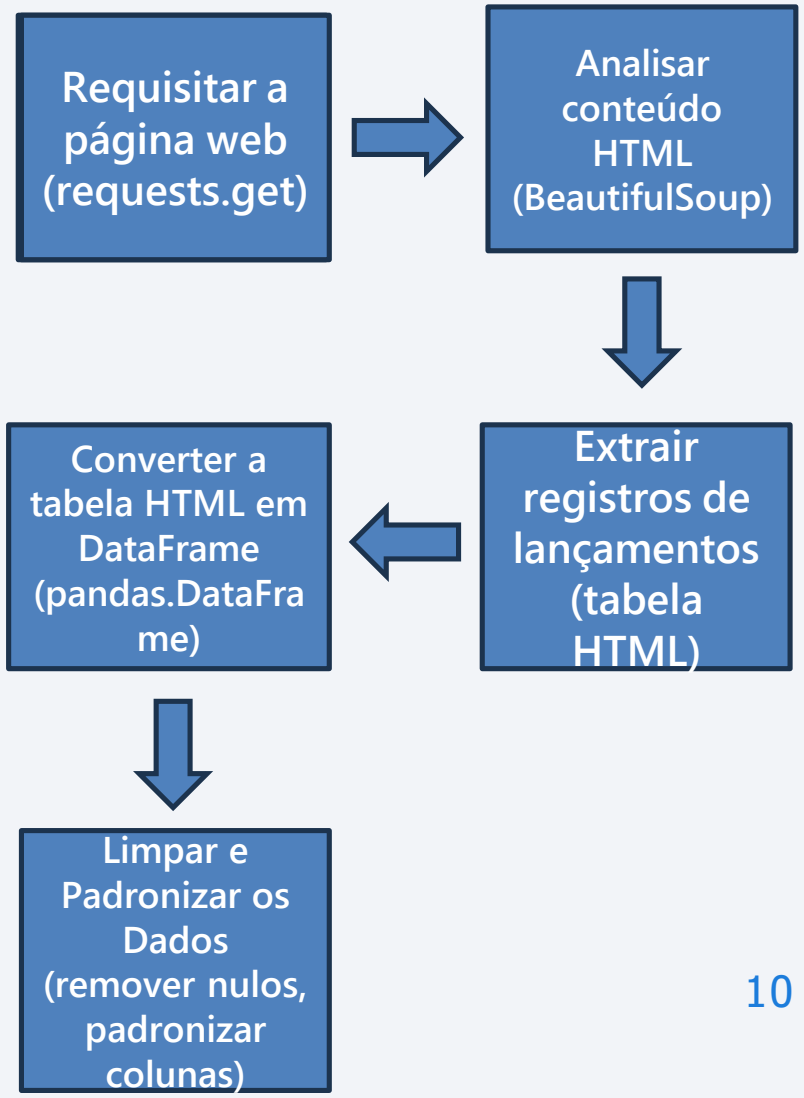

Preparação dos Dados

Visão Geral: Preparação dos Dados (Data Wrangling) envolve limpar, transformar e organizar dados brutos em um formato estruturado adequado para análise.

Etapa 1: Limpeza:

- Identificamos valores ausentes e aplicamos técnicas de imputação ou removemos registros com excesso de falhas.

Etapa 2: Transformação dos Dados:

- Ajustamos os tipos de dados para formatos corretos (datas, números, etc.).
- Padronizamos textos, deixando tudo em minúsculas e sem espaços desnecessários.
- Criamos novas variáveis a partir de informações já existentes, como extrair o ano de uma data.
- Normalizamos e escalamos variáveis numéricas para manter consistência entre os atributos.

Tratamento de Dados (Data Wrangling)

Etapa 3: Integração de Dados

- Consolidar as bases vindas de fontes diferentes (API e raspagem web) em um único conjunto de dados.
- Padronizar os nomes das colunas e alinhar os formatos (datas, textos, categorias) para manter uniformidade entre as tabelas.

Etapa 4: Verificação e Validação de Dados

- Identificar registros repetidos e eliminar duplicatas.
- Revisar se os valores estão corretos e coerentes, garantindo consistência nas informações armazenadas.

URL do GitHub: 3.labs-jupyter-spacex-Data-wrangling.ipynb

Fluxograma de Tratamento de Dados Caixas (Data Wrangling Flowchart)

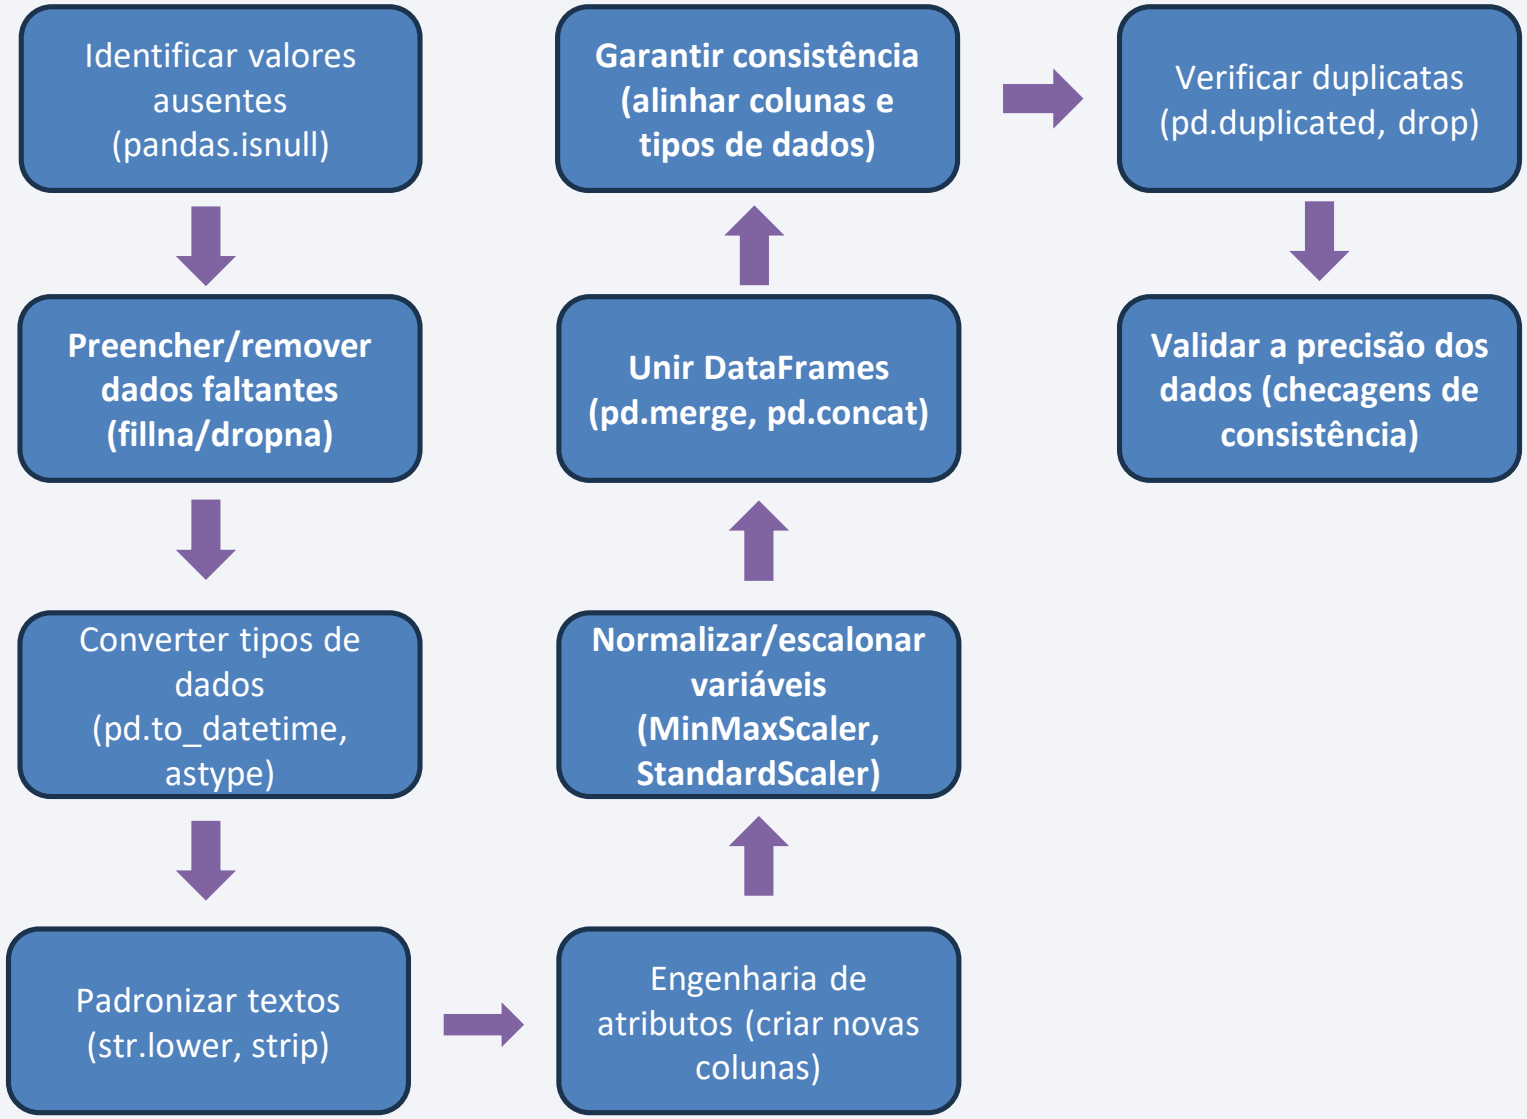

EDA com Visualização de Dados

Resumo:

A EDA (Exploratory Data Analysis) é a etapa em que analisamos o Dataset de forma visual para entender como os dados se comportam. Nessa fase, buscamos enxergar a distribuição das variáveis, encontrar comportamentos recorrentes e observar possíveis relações entre atributos.

Visualizações utilizadas:

1. Histogramas:

- **Finalidade:** Mostrar como variáveis numéricas se distribuem (ex.: sucesso de lançamentos, massa da carga útil, número da missão/voo).
- **Motivo:** Facilita identificar valores extremos, perceber concentração dos dados e avaliar se a distribuição é simétrica ou inclinada.

2. Gráficos de barras:

- **Finalidade:** Comparar categorias (ex.: sucesso vs. falha) entre grupos diferentes, como base de lançamento ou modelo de foguete.
- **Motivo:** Ajuda a enxergar diferenças de proporção/frequência entre categorias e evidenciar padrões de forma direta.

3. Gráficos de linha:

- **Finalidade:** Observar a evolução no tempo, por exemplo a variação da taxa de sucesso do Falcon 9 ao longo dos anos.
- **Motivo:** Permite detectar tendências, mudanças de comportamento e possíveis períodos de melhora ou queda de performance.

EDA com Visualização de Dados

4. Gráfico de dispersão:

- **Finalidade:** Analisar a relação entre duas métricas numéricas (ex.: massa da carga útil em função do sucesso do lançamento).
- **Motivo:** Permite perceber padrões de associação, tendência e possível dependência entre as variáveis.

5. Heatmap de correlação:

- **Finalidade:** Representar, de forma visual, a correlação entre várias variáveis numéricas ao mesmo tempo.
- **Motivo:** Facilita encontrar relações fortes (para mais ou para menos) e ajuda a decidir quais variáveis usar, além de apontar possíveis problemas de multicolinearidade.

6. Boxplot:

- **Finalidade:** Resumir a distribuição dos valores usando mediana e quartis.
- **Motivo:** Ajuda a comparar grupos, enxergar a variabilidade dos dados e identificar valores fora do padrão (outliers).

URL do GitHub: 5. jupyter-labs-eda-dataviz.ipynb

EDA utilizando SQL

Consultas de agregação:

- Obteve a quantidade total de lançamentos no conjunto de dados.
- Separou a contagem de lançamentos em sucesso e falha.
- Estimou o percentual de sucesso por base de lançamento e por modelo/tipo de foguete.

Consultas com JOIN:

- Relacionou tabelas para enriquecer os lançamentos com informações complementares (por exemplo, dados do foguete).
- Unificou fontes/tabelas para permitir uma visão mais abrangente da análise.

Consultas de filtragem:

- Aplicou filtros para analisar cenários específicos (como apenas sucessos ou apenas falhas).
- Definiu critérios (data, configuração do foguete, etc.) para selecionar subconjuntos relevantes de lançamentos.

Consultas de ordenação:

- Ordenou registros para facilitar a identificação de padrões e valores fora do comportamento comum.
- Classificou lançamentos por data e/ou indicadores de desempenho (ex.: taxa de sucesso).

Subconsultas:

- Utilizou consultas dentro de consultas para gerar indicadores calculados (ex.: média de carga útil por local).
- Empregou subqueries para detalhar análises sem perder o contexto do conjunto principal de dados.

URL do GitHub: 4. jupyter-labs-eda-sql-coursera_sqllite.ipynb

Criando um Mapa Interativo com Folium

Elementos adicionados ao mapa

Marcadores:

- Inseriu marcadores para destacar as bases/locais de lançamento no mapa.
- Cada marcador indica um ponto geográfico exato onde ocorreram missões/lançamentos da SpaceX.

Círculos:

- Criou círculos em torno dos locais para representar áreas de alcance/raio de proximidade.
- Esses círculos ajudam a enxergar regiões ao redor da base que podem ter relevância para análise operacional.

Linhas:

- Traçou linhas ligando locais de lançamento a pontos próximos ou a outras referências importantes.
- As linhas ajudam a contextualizar a relação espacial entre diferentes pontos associados aos lançamentos.

Justificativas para usar esses elementos

Marcadores:

- Marcar a posição exata dos lançamentos para facilitar a leitura geográfica.
- Permite visualizar rapidamente a distribuição espacial dos lançamentos da SpaceX.

Círculos:

- Indicar visualmente regiões de influência/impacto ao redor das bases.
- Representar limites de segurança ou áreas operacionais de forma intuitiva.

Linhas:

- Evidenciar ligações/associações entre locais e informações relevantes no mapa.
- Ajuda a interpretar dependências e padrões espaciais entre os pontos.

- URL do GitHub: 6. lab_jupyter_launch_site_location.ipynb

Criação de um Dashboard Interativo com Plotly Dash

Visualizações incluídas

Gráfico de pizza (Sucesso/Falha):

- Apresenta a proporção entre lançamentos com sucesso e lançamentos com falha.
- Ajuda a ter uma visão rápida do desempenho geral e do comportamento do indicador de sucesso.

Dispersão: Sucesso vs. Massa da carga útil:

- Exibe como a massa da carga útil se relaciona com o resultado do lançamento.
- Permite investigar se cargas mais leves ou mais pesadas estão associadas a maior taxa de sucesso.

Componentes interativos

Seleção por base de lançamento (Dropdown):

- Possibilita escolher uma base/local específico para filtrar a análise
- Direciona a exploração dos dados para comparações por região/localidade.

Slider de intervalo da carga útil:

- Deixa o usuário definir a faixa de massa que quer analisar em tempo real.
- Ajuda a comparar o desempenho dos lançamentos em diferentes intervalos de carga útil.

- URL do GitHub: spacex_dash_app.py

Motivos para adicionar gráficos e interações

Gráfico de pizza (sucesso/falha):

- Resume rapidamente a proporção de missões bem-sucedidas versus falhas.
- Ajuda o público e os responsáveis pelo projeto a captar o desempenho geral “de primeira”, sem esforço.

Dispersão: sucesso vs. atributos da carga útil:

- Facilita enxergar se existe relação entre a carga útil (especialmente a massa) e o resultado do lançamento.
- Dá suporte a decisões de planejamento, ajudando a orientar escolhas operacionais e de configuração da missão.

Seleção por local de lançamento (Dropdown):

- Deixa a análise mais direcionada ao permitir filtrar por base/localidade.
- Torna possível comparar resultados entre regiões e identificar diferenças entre sites de lançamento.

Slider de intervalo da carga útil:

- Permite testar faixas de massa e observar como isso impacta a taxa de sucesso.
- Ajuda a aprofundar a investigação de desempenho em cenários específicos ligados à carga útil.

Modelagem Preditiva (Classificação)

1. Preparação dos dados:

- Aplicou padronização/escala nas features para manter comparabilidade entre variáveis.
- Separou a base em treino e teste para avaliar o desempenho de forma justa.

2. Escolha de algoritmos:

- Testou diferentes classificadores, incluindo SVM, Decision Tree e KNN.
- Selecionou modelos apropriados para prever um resultado binário conforme o objetivo do projeto.

3. Otimização de hiperparâmetros:

- Utilizou GridSearchCV para encontrar combinações melhores de parâmetros.
- Regulou configurações como C no SVM, profundidade máxima na árvore e número de vizinhos no KNN.

4. Medição de desempenho:

- Usou validação cruzada para verificar estabilidade e generalização dos modelos.
- Comparou desempenho com métricas de classificação: accuracy, precision, recall e F1.

5. Refinamento iterativo:

- Reajustou modelos com base no que foi observado nos testes/validações.
- Fez ajustes finos para melhorar a capacidade de predição e reduzir erros.

6. Definição do modelo final:

- Escolheu como modelo final aquele que apresentou melhor resultado no conjunto de teste.
- Checou treino vs. teste para reduzir risco de overfitting e aumentar confiança na aplicação prática.

- URL do GitHub: 7. SpaceX_Machine_Learning_Prediction_Part_5.jupyterlite.ipynb

Modelagem Preditiva (Fluxo)

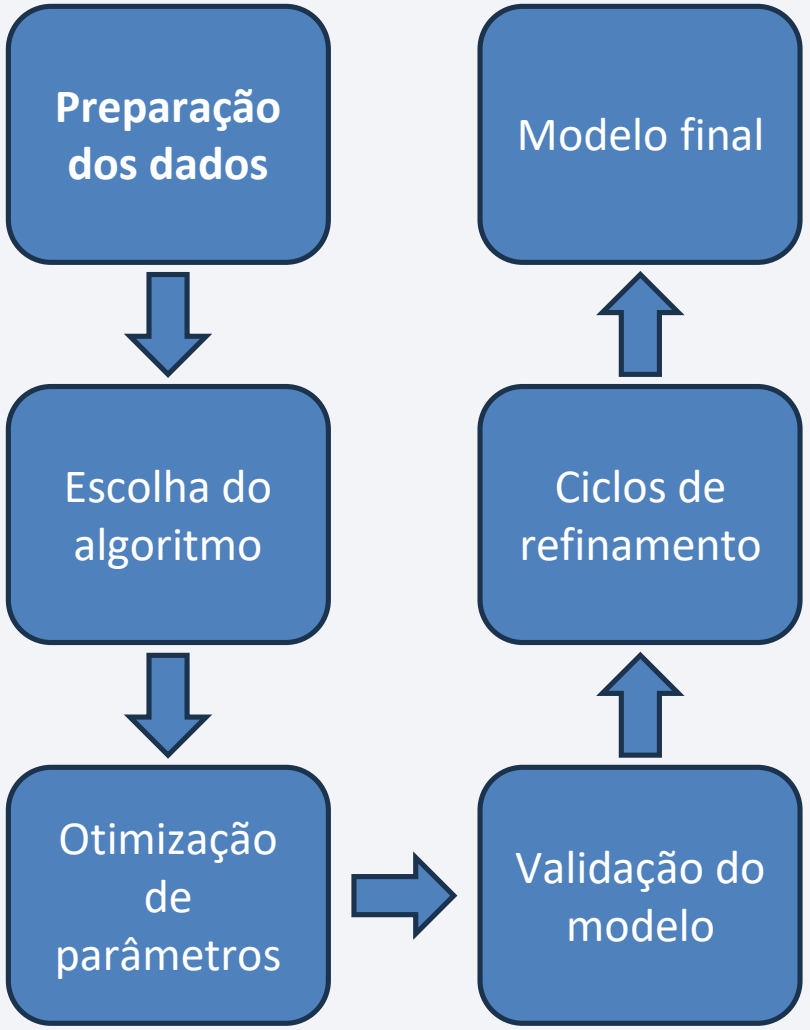

```python
# Visualize Flight Number vs Launch Site with a clearer success/failure legend
plot_df = df.copy()
plot_df['LandingResult'] = plot_df['Class'].map({0: 'Failure', 1: 'Success'})

g = sns.catplot(
    data=plot_df,
    x='FlightNumber',
    y='LaunchSite',
    hue='LandingResult',
    kind='strip',
    aspect=2.8,
    height=6,
    palette={'Failure': '#d95f02', 'Success': '#1b9e77'}
)
g.set_axis_labels('Flight Number', 'Launch Site')
g.fig.suptitle('Flight Number vs Launch Site by Landing Result', y=1.02, fontsize=16)
plt.show()
```

✓ 1.5s

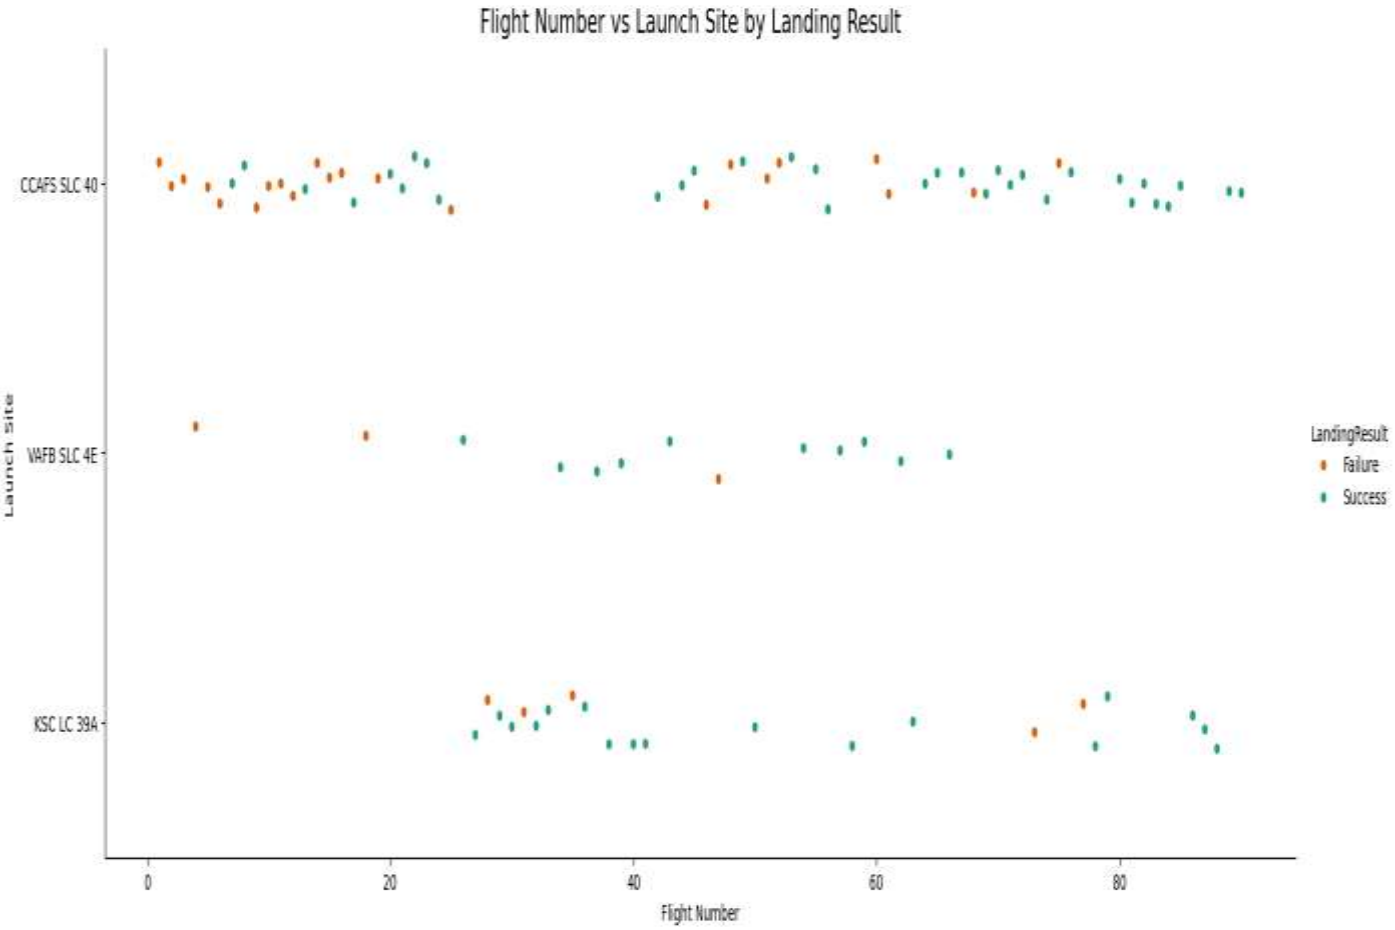

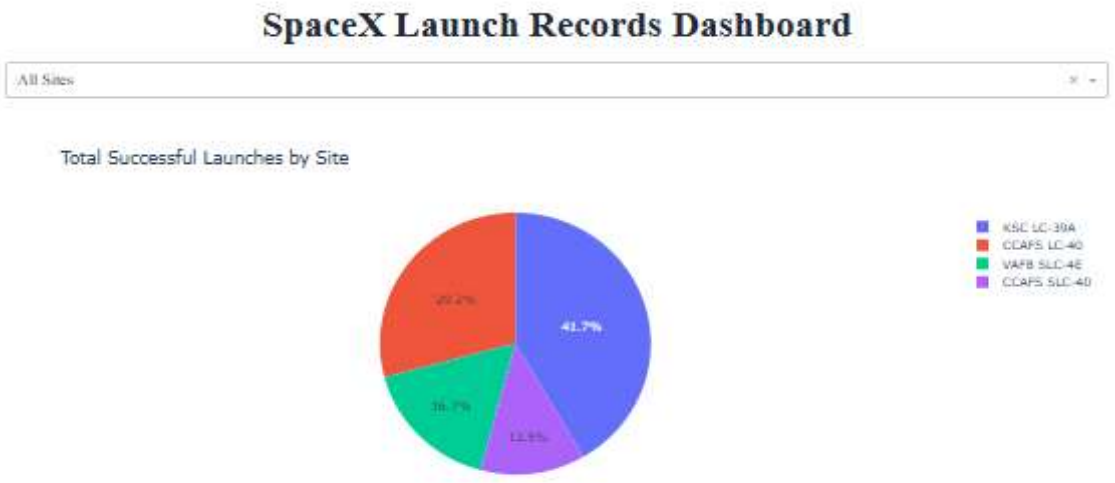

Bullets:

- Principais achados da EDA (análise exploratória)
- Exemplos do dashboard/análises interativas (prints)
- Desempenho e resultados dos modelos preditivos

Seção 2

Insights drawn from EDA

Número da missão vs. Base de lançamento

- **Resultados variados nas principais bases:** Em CCAFS SLC 40 e KSC LC 39A aparecem tanto pousos com sucesso (laranja) quanto falhas (azul), o que sugere que o local, sozinho, não explica o desempenho — outros fatores devem estar influenciando.

- **Distribuição estável ao longo dos voos:** Os lançamentos se espalham por muitos números de voo em todas as bases, indicando constância de operações e sem evidência de uma tendência forte (para cima ou para baixo) na taxa de sucesso de pouso.

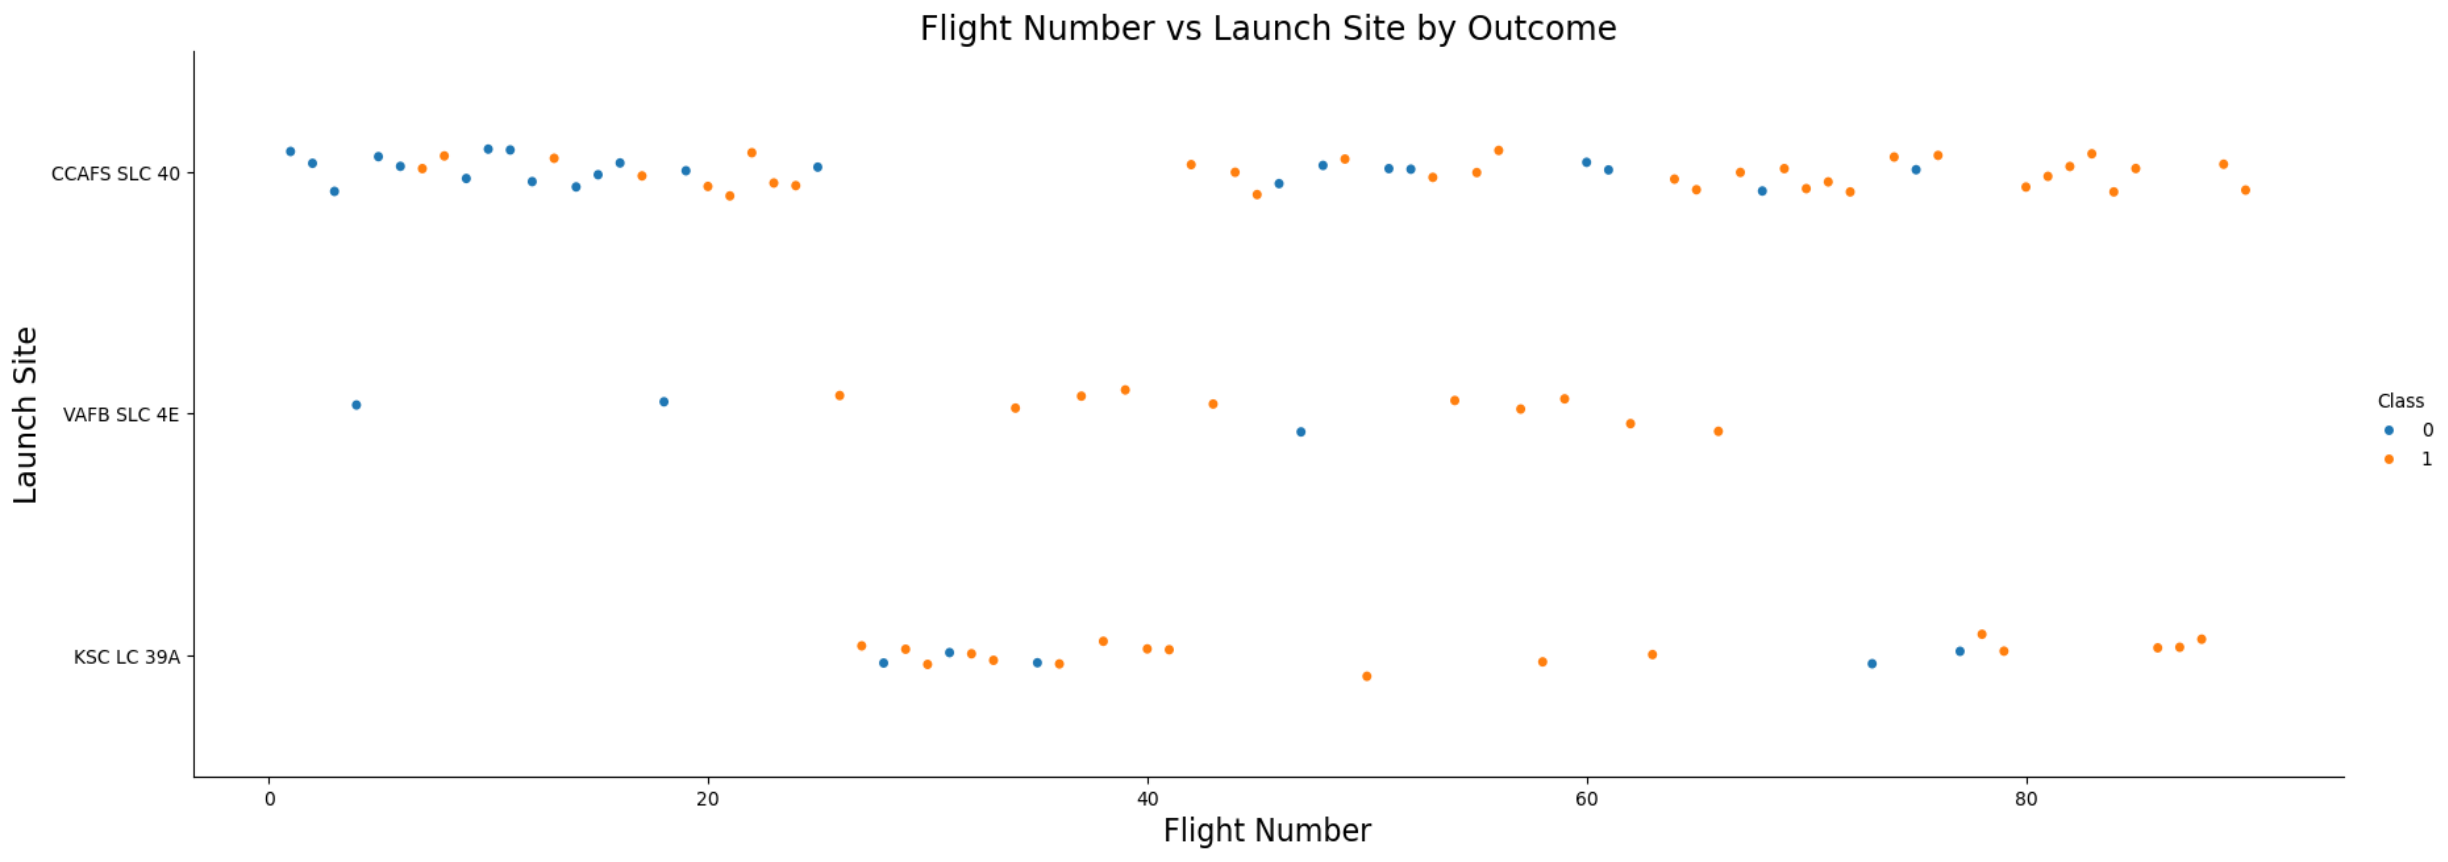

Carga útil VS Local de lançamento

- **Padrão de cargas por local**: No CCAFS SLC 40, as missões tendem a levar cargas mais leves (geralmente abaixo de 10 toneladas). Já VAFB SLC 4E e KSC LC 39A mostram maior diversidade de massas, o que aponta para diferentes tipos de missão.
- **Missões mais pesadas concentradas no KSC:** O KSC LC 39A aparece com frequência em lançamentos de cargas mais altas, inclusive acima de 15 toneladas, indicando que é uma base comum para operações de maior porte.

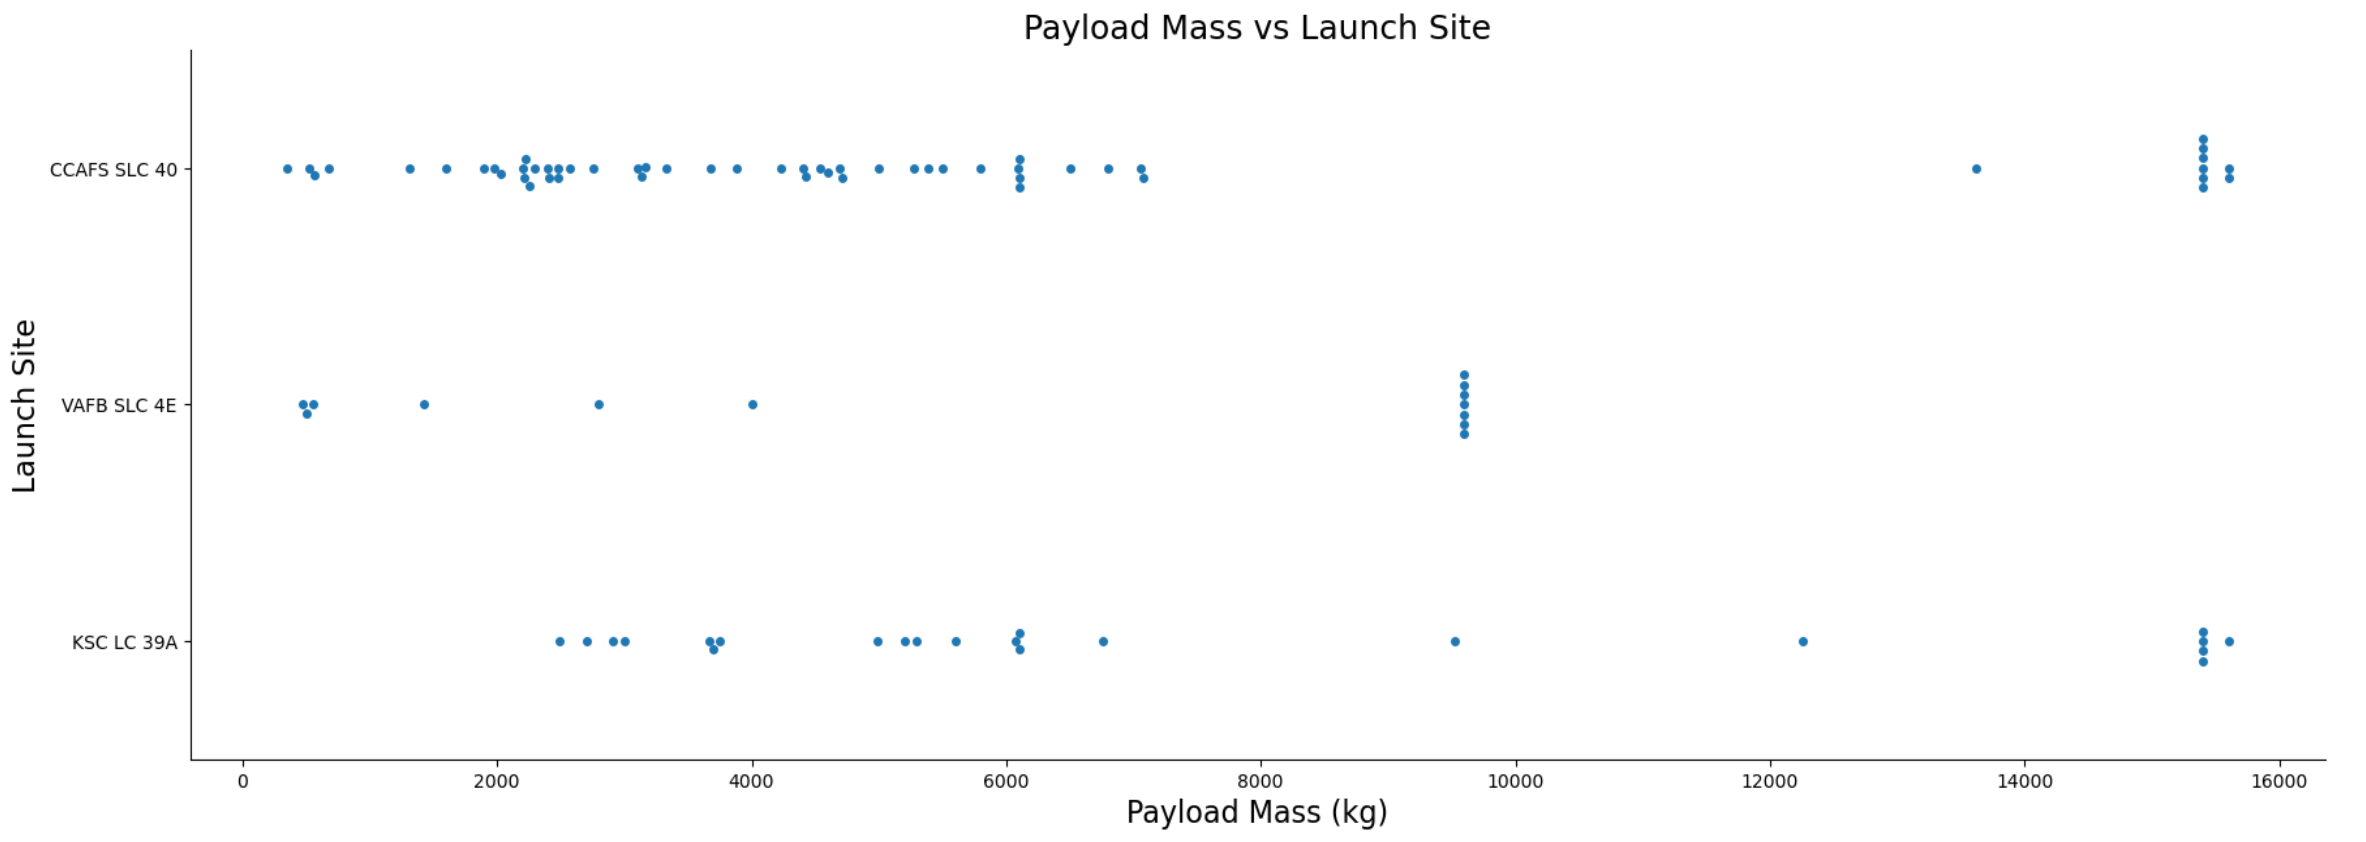

Taxa de sucesso VS Tipo de órbita

- **Altas taxas de sucesso:** Para VLEO, ES-L1, GEO, HEO e SSO, os resultados mostram sucesso total, o que aponta alta confiabilidade de pouso do primeiro estágio nesses perfis de missão.

- **Menor taxa de sucesso para GTO:** Em **GTO**, a taxa de sucesso fica bem abaixo das demais, indicando que esse tipo de missão tende a ser mais exigente e pode aumentar a chance de falha no pouso.

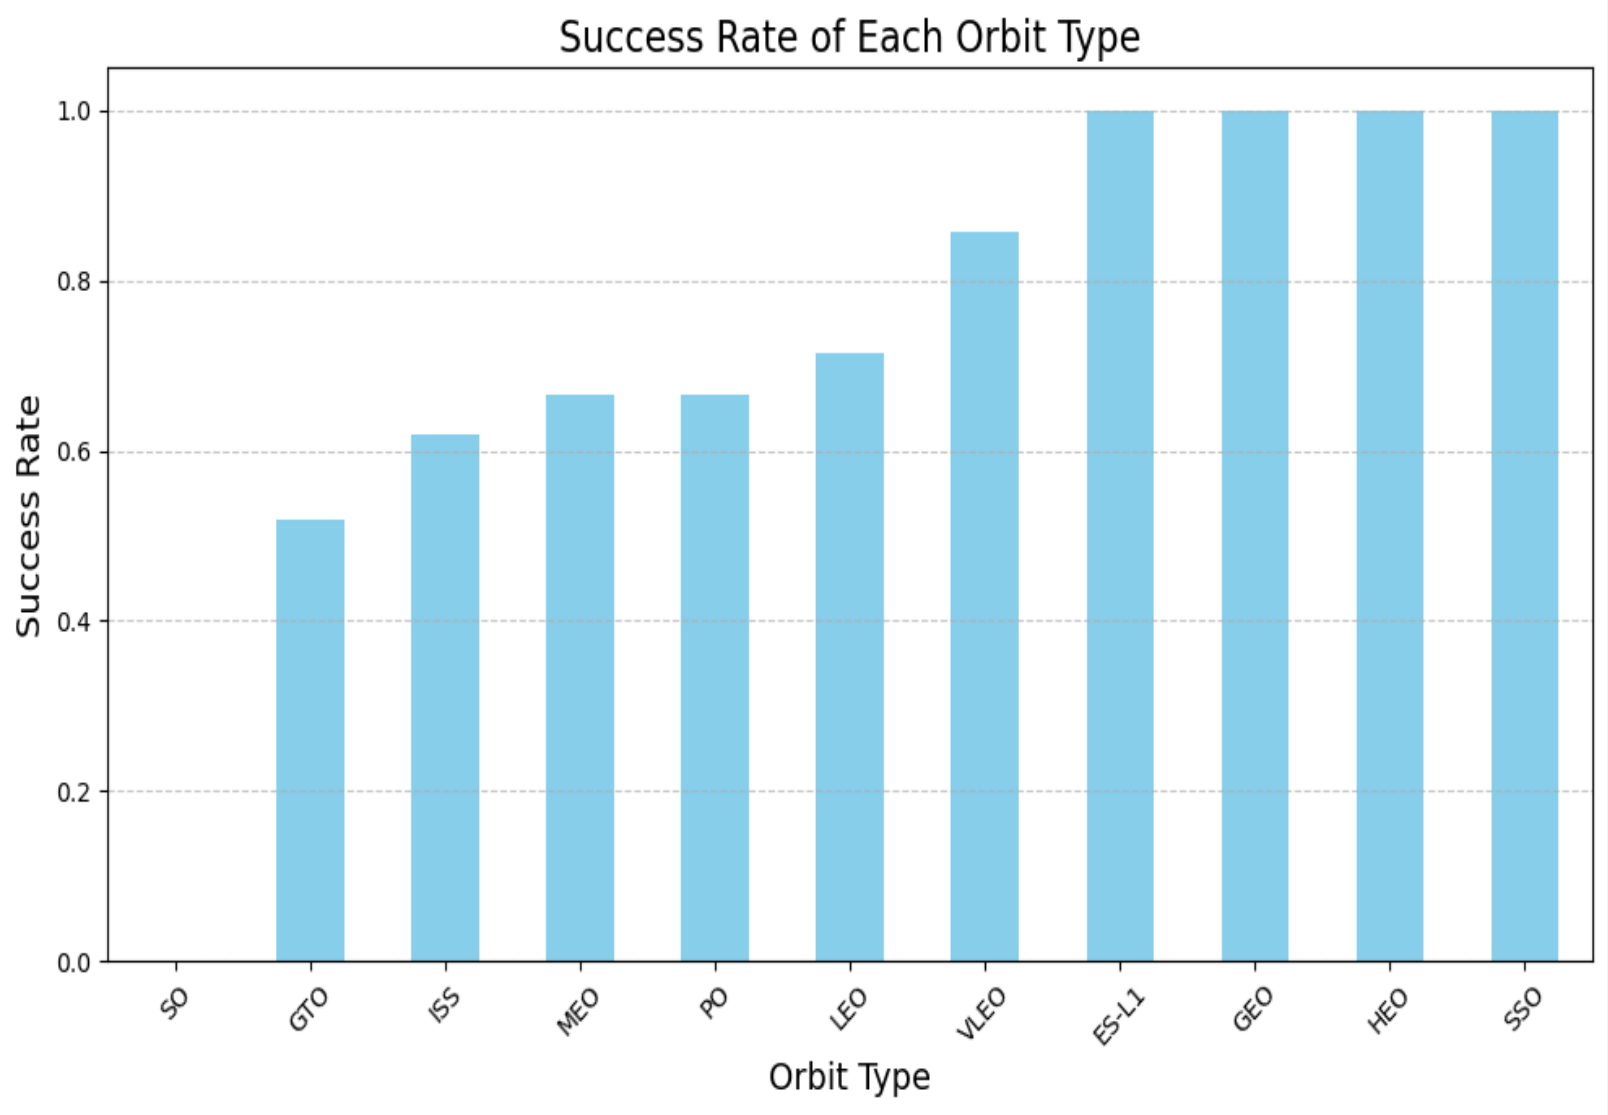

Número do voo VS Tipo de órbita

- **Melhora progressiva com a experiência:** Conforme o número de missões aumenta, a taxa de sucesso do Falcon 9 tende a subir, sugerindo aprendizado operacional e otimizações contínuas ao longo do programa.

- **Mudança de padrão em órbitas específicas:** Nas primeiras missões para GTO e ISS houve mais variação de resultado; nas missões mais recentes, o desempenho é superior, indicando maturidade no planejamento e na execução desses perfis de voo.

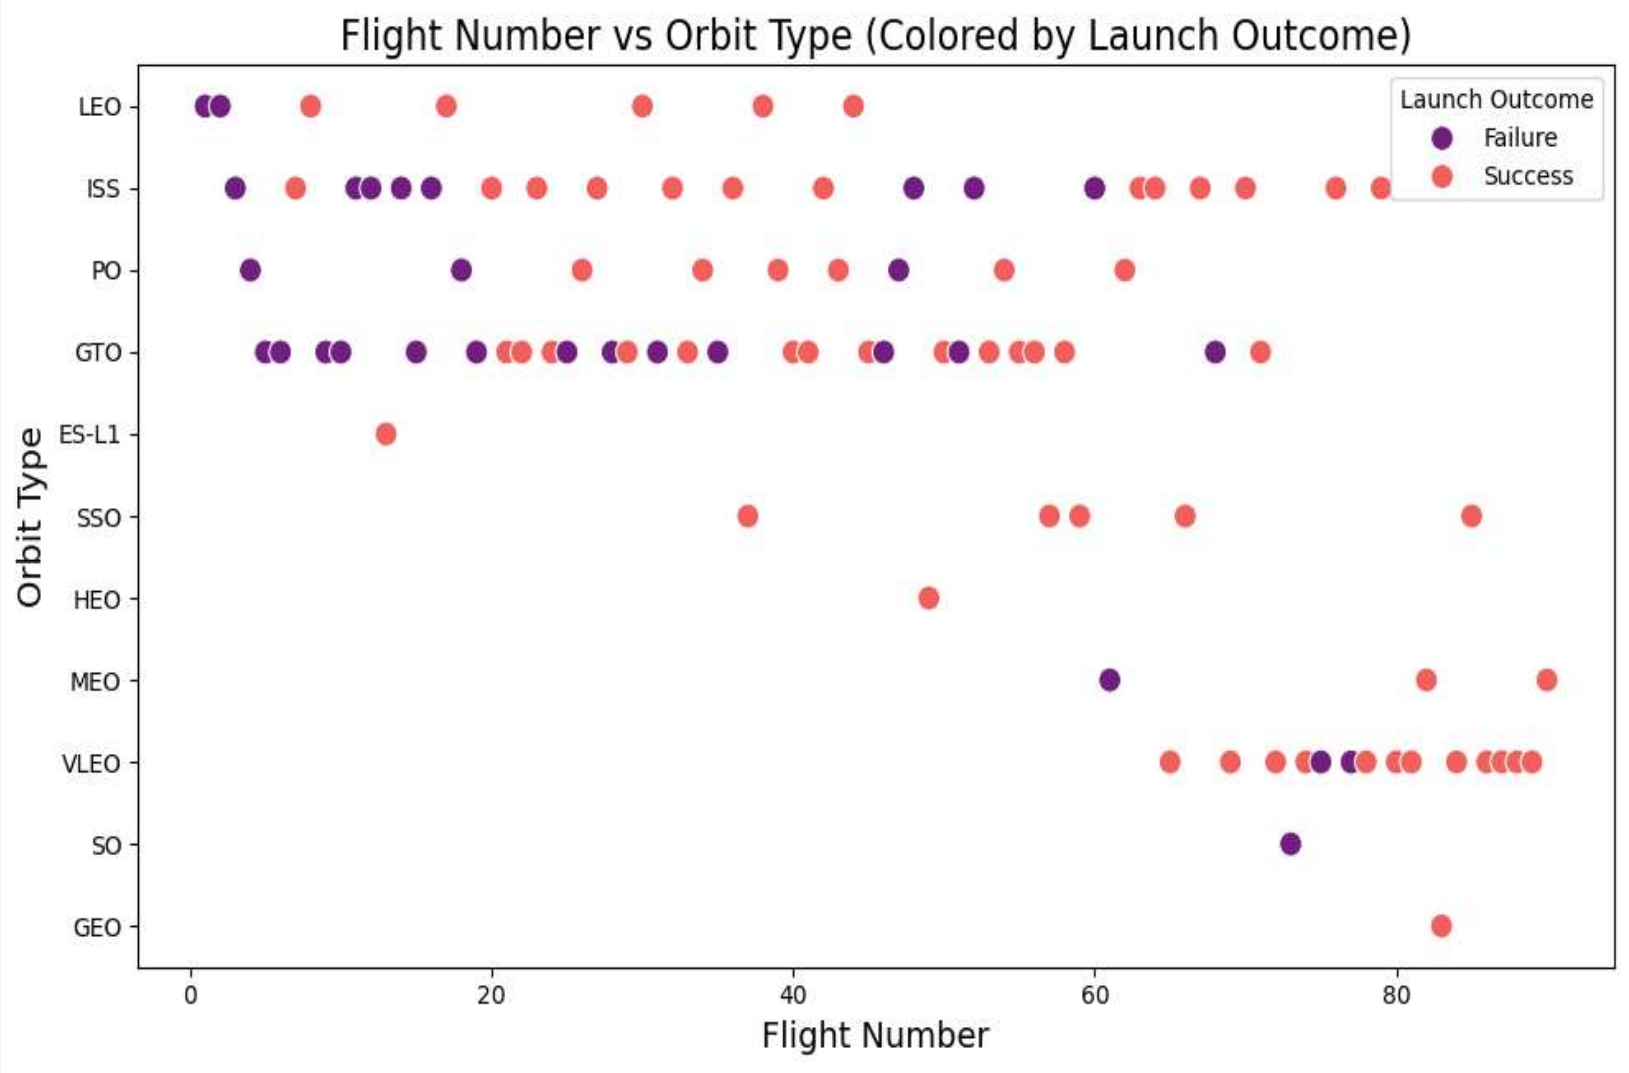

Carga útil VS Tipo de órbita

- Em diferentes órbitas, observa-se maior taxa de pouso bem-sucedido quando a carga útil é mais leve, principalmente abaixo de 6 toneladas.

- Para cargas acima de 10 toneladas, os resultados ficam menos consistentes (há sucesso e falha), sugerindo que o aumento de massa torna a missão mais exigente.

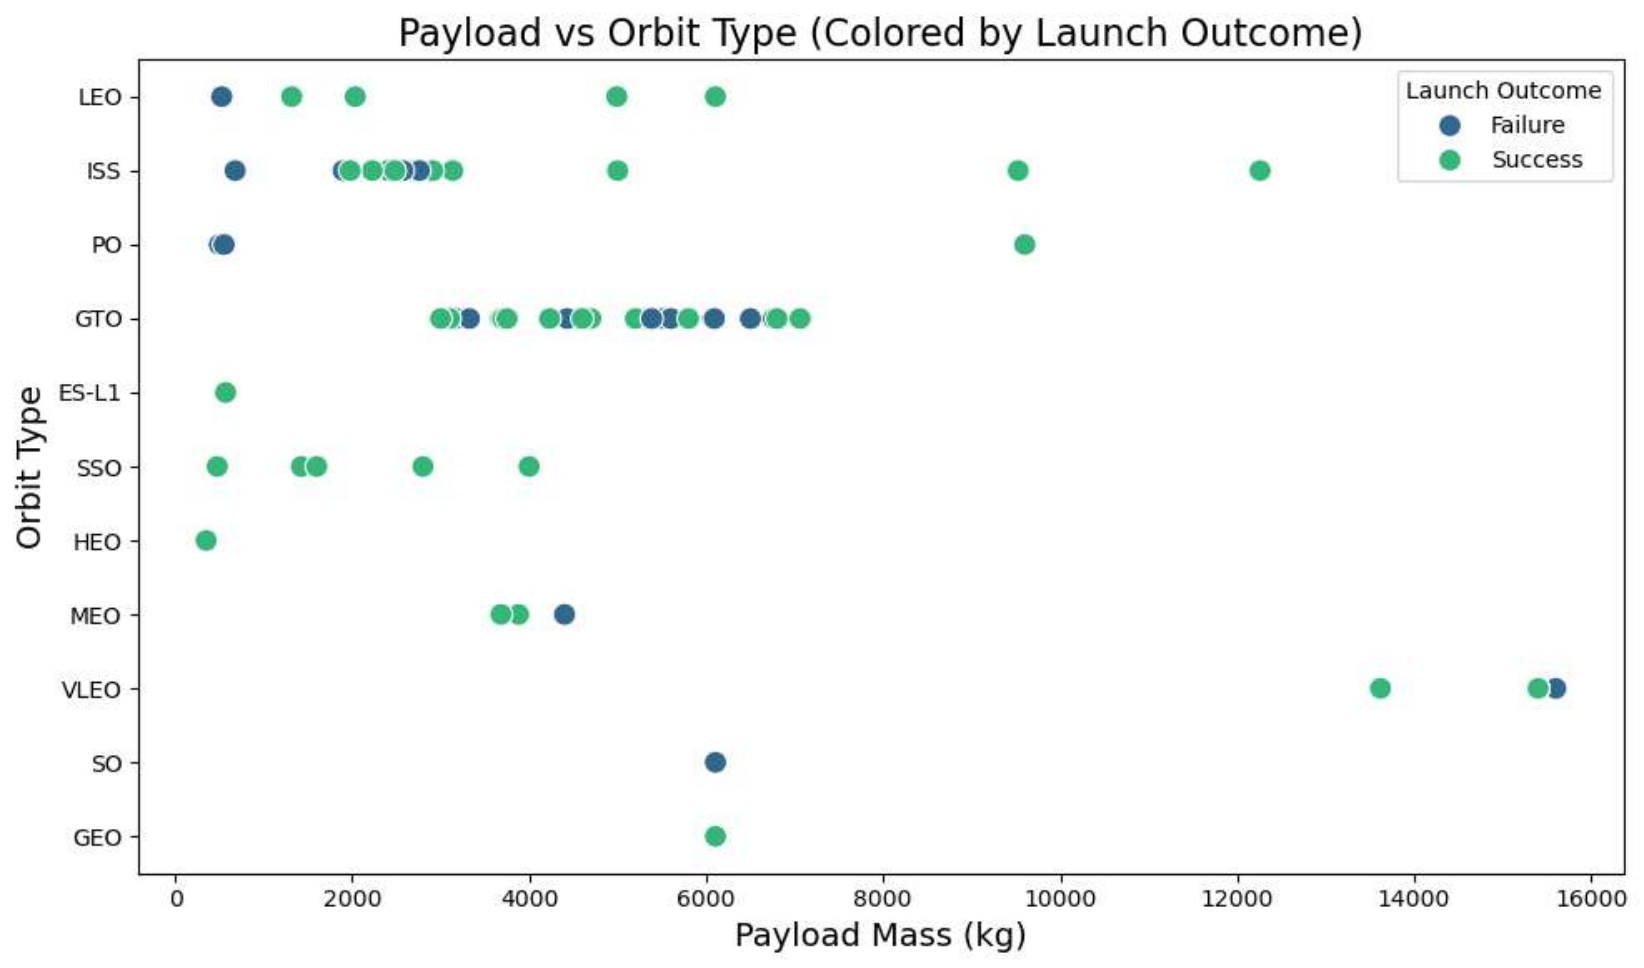

Evolução anual da taxa de sucesso

- A partir de 2013, observa-se crescimento consistente na taxa de sucesso, ultrapassando 80% por volta de 2020.

- Mesmo com uma oscilação negativa em 2018, o panorama geral aponta melhoria contínua na confiabilidade do Falcon 9 ao longo do tempo.

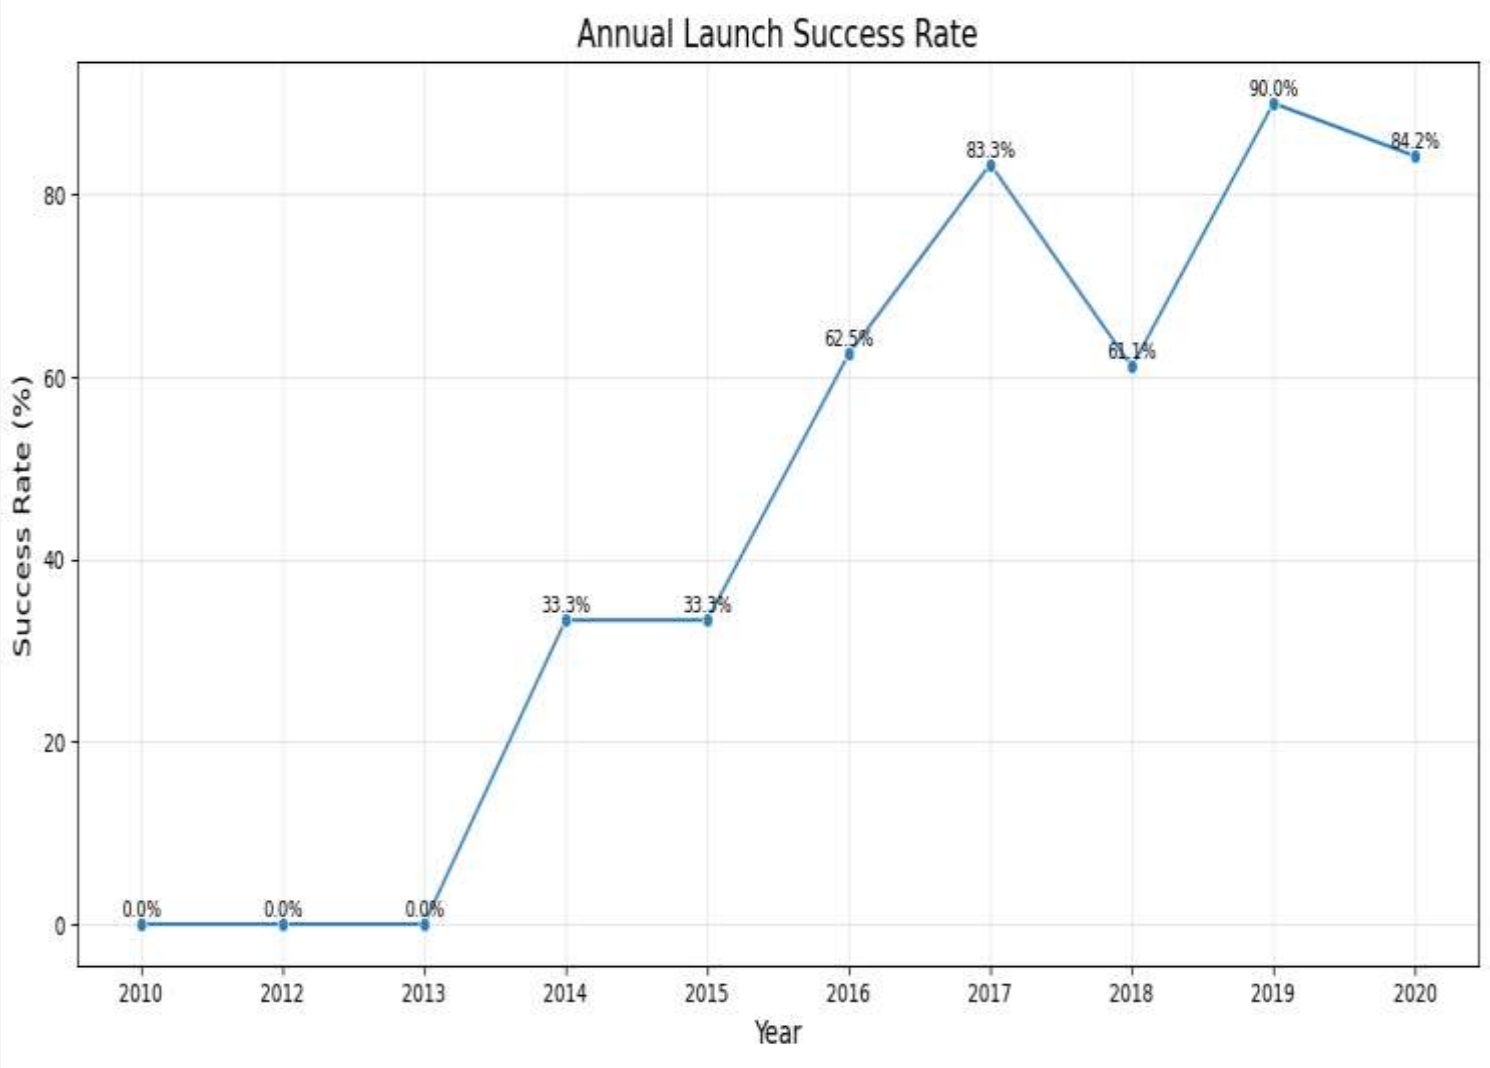

Lista de locais de lançamento

Task 1

Display the names of the unique launch sites in the space mission

```
pd.read_sql_query("""
SELECT DISTINCT "Launch_Site"
FROM SPACEXTABLE;
""", con)
```

	Launch_Site
0	CCAFS LC-40
1	VAFB SLC-4E
2	KSC LC-39A
3	CCAFS SLC-40

Nomes dos locais de lançamento que começam com "CCA"

Task 2

Display 5 records where launch sites begin with the string 'CCA'

```
pd.read_sql_query("""
SELECT *
FROM SPACEXTABLE
WHERE "Launch_Site" LIKE 'CCA%'
LIMIT 5;
""", con)
```

✓ 0.3s Python

	Date	Time (UTC)	Booster_Version	Launch_Site	Payload	PAYLOAD_MASS__KG_	Orbit	Customer	Mission_Outcome	Landing_Outcome
0	2010-06-04	18:45:00	F9 v1.0 B0003	CCAFS LC-40	Dragon Spacecraft Qualification Unit	0	LEO	SpaceX	Success	Failure (parachute)
1	2010-12-08	15:43:00	F9 v1.0 B0004	CCAFS LC-40	Dragon demo flight C1, two CubeSats, barrel of...	0	LEO (ISS)	NASA (COTS) NRO	Success	Failure (parachute)
2	2012-05-22	7:44:00	F9 v1.0 B0005	CCAFS LC-40	Dragon demo flight C2	525	LEO (ISS)	NASA (COTS)	Success	No attempt
3	2012-10-08	0:35:00	F9 v1.0 B0006	CCAFS LC-40	SpaceX CRS-1	500	LEO (ISS)	NASA (CRS)	Success	No attempt
4	2013-03-01	15:10:00	F9 v1.0 B0007	CCAFS LC-40	SpaceX CRS-2	677	LEO (ISS)	NASA (CRS)	Success	No attempt

Massa total da carga útil

Task 3

Display the total payload mass carried by boosters launched by NASA (CRS)

```
pd.read_sql_query("""
SELECT SUM("PAYLOAD_MASS__KG_") AS "Total_Payload_NASA_CRS"
FROM SPACEXTABLE
WHERE "Customer" = 'NASA (CRS)';
""", con)
```

✓ 0.0s Python

	Total_Payload_NASA_CRS
0	45596

Massa média da carga útil por F9 v1.1

Task 4

Display average payload mass carried by booster version F9 v1.1

```
pd.read_sql_query("""
SELECT AVG("PAYLOAD_MASS__KG_") AS "Avg_Payload_F9_v1_1"
FROM SPACEXTABLE
WHERE "Booster_Version" = 'F9 v1.1';
""", con)
```

✓ 0.0s Python

	Avg_Payload_F9_v1_1
0	2928.4

Data do primeiro pouso em solo com sucesso

Task 5

List the date when the first succesful landing outcome in ground pad was acheived.

Hint:Use min function

```
pd.read_sql_query("""
SELECT MIN("Date") AS "First_Successful_Ground_Landing_Date"
FROM SPACEXTABLE
WHERE "Landing_Outcome" = 'Success (ground pad)';
""", con)
```

✓ 0.0s Python

	First_Successful_Ground_Landing_Date
0	2015-12-22

Pouso em navio-drone com sucesso (carga útil: 4-6 mil)

Task 6

List the names of the boosters which have success in drone ship and have payload mass greater than 4000 but less than 6000

```python
pd.read_sql_query("""
SELECT DISTINCT "Booster_Version"
FROM SPACEXTABLE
WHERE "Landing_Outcome" = 'Success (drone ship)'
  AND "PAYLOAD_MASS__KG_" > 4000
  AND "PAYLOAD_MASS__KG_" < 6000;
""", con)
```

✓ 0.1s Python

	Booster_Version
0	F9 FT B1022
1	F9 FT B1026
2	F9 FT B1021.2
3	F9 FT B1031.2

Total de resultados de missão (sucesso/falha)

- No recorte desta consulta, o resultado retornou apenas Success = 98.

Task 7

List the total number of successful and failure mission outcomes

```python
pd.read_sql_query("""
SELECT "Mission_Outcome", COUNT(*) AS "Total"
FROM SPACEXTABLE
WHERE "Mission_Outcome" IN ('Success', 'Failure')
GROUP BY "Mission_Outcome";
""", con)
```

✓ 0.0s Python

	Mission_Outcome	Total
0	Success	98

Boosters responsáveis pela maior carga útil

Task 8

List the names of the booster_versions which have carried the maximum payload mass. Use a subquery

```
pd.read_sql_query("""
SELECT DISTINCT "Booster_Version"
FROM SPACEXTABLE
WHERE "PAYLOAD_MASS__KG_" = (
    SELECT MAX("PAYLOAD_MASS__KG_")
    FROM SPACEXTABLE
);
""", con)
```

✓ 0.0s Python

	Booster_Version
0	F9 B5 B1048.4
1	F9 B5 B1049.4
2	F9 B5 B1051.3
3	F9 B5 B1056.4
4	F9 B5 B1048.5
5	F9 B5 B1051.4
6	F9 B5 B1049.5
7	F9 B5 B1060.2
8	F9 B5 B1058.3
9	F9 B5 B1051.6
10	F9 B5 B1060.3
11	F9 B5 B1049.7

Lançamentos realizados em 2015

Task 9

List the records which will display the month names, failure landing_outcomes in drone ship ,booster versions, launch_site for the months in year 2015.

Note: SQLLite does not support monthnames. So you need to use substr(Date, 6,2) as month to get the months and substr(Date,0,5)='2015' for year.

```
pd.read_sql_query("""
SELECT
    CASE
        WHEN substr("Date", 6, 2) = '01' THEN 'January'
        WHEN substr("Date", 6, 2) = '02' THEN 'February'
        WHEN substr("Date", 6, 2) = '03' THEN 'March'
        WHEN substr("Date", 6, 2) = '04' THEN 'April'
        WHEN substr("Date", 6, 2) = '05' THEN 'May'
        WHEN substr("Date", 6, 2) = '06' THEN 'June'
        WHEN substr("Date", 6, 2) = '07' THEN 'July'
        WHEN substr("Date", 6, 2) = '08' THEN 'August'
        WHEN substr("Date", 6, 2) = '09' THEN 'September'
        WHEN substr("Date", 6, 2) = '10' THEN 'October'
        WHEN substr("Date", 6, 2) = '11' THEN 'November'
        WHEN substr("Date", 6, 2) = '12' THEN 'December'
        ELSE 'Unknown'
    END AS "Month_Name",
    "Mission_Outcome",
    "Booster_Version",
    "Launch_Site"
FROM SPACEXTABLE
WHERE substr("Date", 1, 4) = '2015';
""", con)
```

✓ 0.0s Python

	Month_Name	Mission_Outcome	Booster_Version	Launch_Site
0	January	Success	F9 v1.1 B1012	CCAFS LC-40
1	February	Success	F9 v1.1 B1013	CCAFS LC-40
2	March	Success	F9 v1.1 B1014	CCAFS LC-40
3	April	Success	F9 v1.1 B1015	CCAFS LC-40
4	April	Success	F9 v1.1 B1016	CCAFS LC-40
5	June	Failure (in flight)	F9 v1.1 B1018	CCAFS LC-40
6	December	Success	F9 FT B1019	CCAFS LC-40

Ranking dos resultados de pouso (2010-06-04 a 2017-03-20)

Task 10

Rank the count of landing outcomes (such as Failure (drone ship) or Success (ground pad)) between the date 2010-06-04 and 2017-03-20, in descending order.

```
pd.read_sql_query("""
SELECT
    "Landing_Outcome",
    COUNT(*) AS "Count"
FROM SPACEXTABLE
WHERE "Date" BETWEEN '2010-06-04' AND '2017-03-20'
GROUP BY "Landing_Outcome"
ORDER BY COUNT(*) DESC;
""", con)
```

✓ 0.0s Python

	Landing_Outcome	Count
0	No attempt	10
1	Success (drone ship)	5
2	Failure (drone ship)	5
3	Success (ground pad)	3
4	Controlled (ocean)	3
5	Uncontrolled (ocean)	2
6	Failure (parachute)	2
7	Precluded (drone ship)	1

Seção 3

Launch Sites Proximities Analysis

Tarefa 1: Marcar todos os locais de

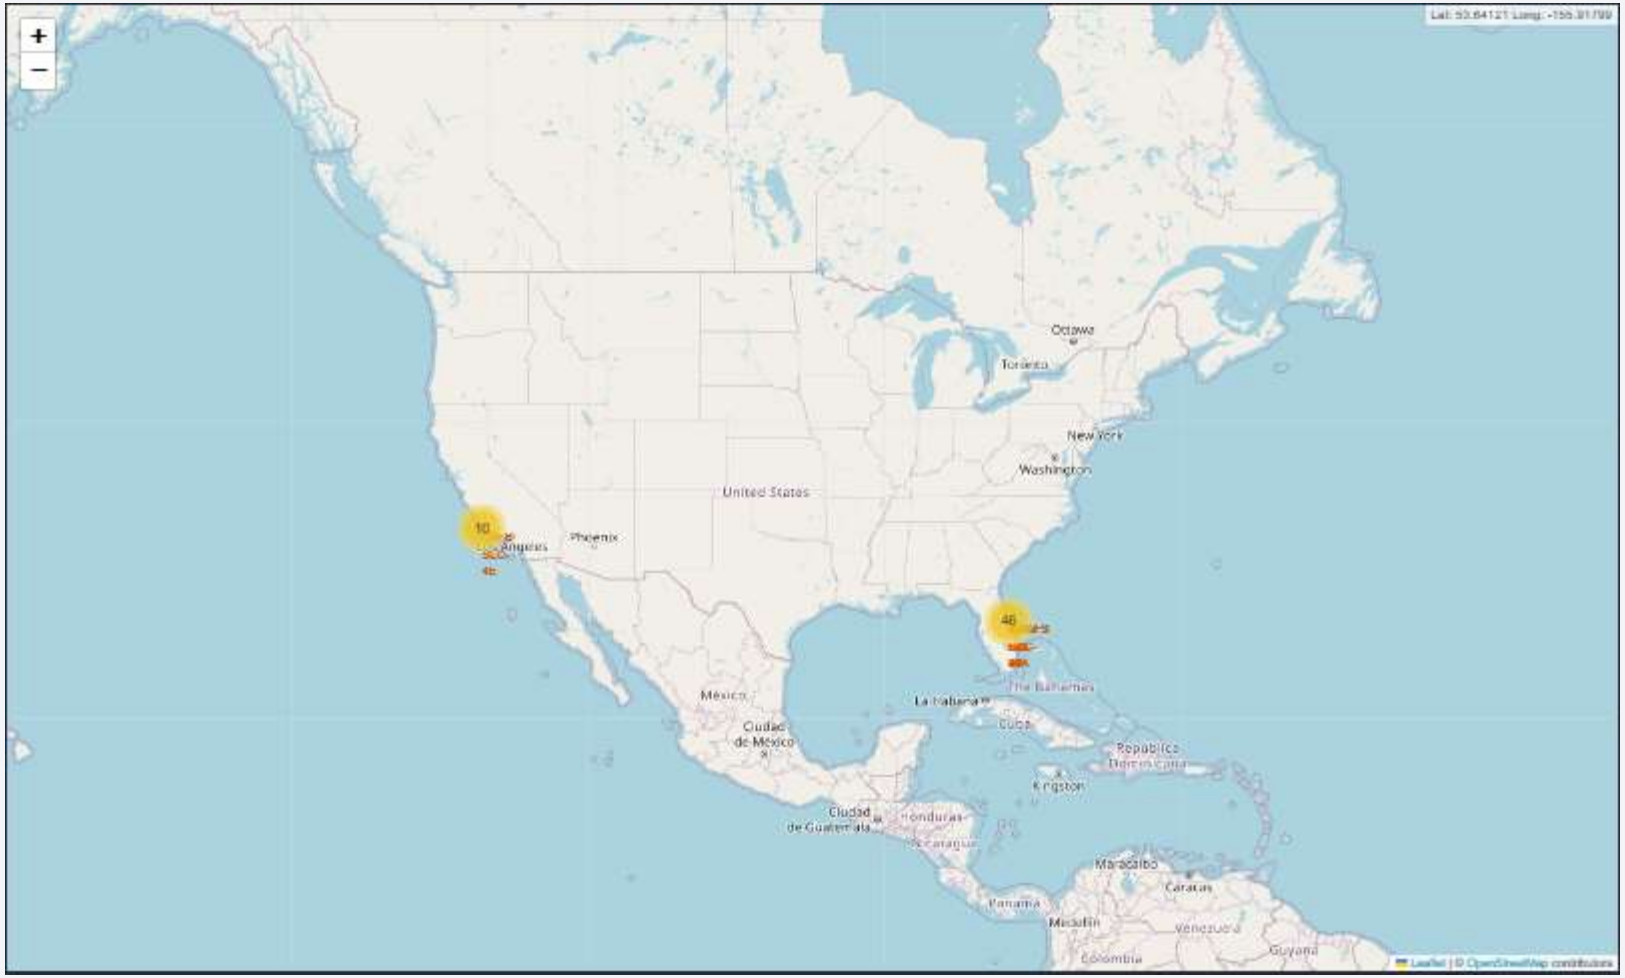

1. Os locais de lançamento estão próximos do Equador?

- Não. Existe variação de latitude entre as bases, então nem todas ficam perto da linha do Equador.
- A base VAFB SLC-4E (Vandenberg) fica em torno de 34,63° de latitude, bem mais afastada do Equador do que as bases localizadas na Flórida.

2. As bases de lançamento ficam próximas do litoral?

- Sim. As bases analisadas estão em regiões costeiras ou muito próximas da costa.
- CCAFS (LC-40/SLC-40) e KSC (LC-39A) ficam no litoral da Flórida.
- VAFB SLC-4E também está próxima ao litoral, na Califórnia.

Tarefa 2: Indicar no mapa quais lançamentos foram sucesso ou falha por base

- Para melhorar a leitura do mapa, foi utilizado agrupamento de marcadores, o que torna a visualização mais limpa quando há muitos pontos. Isso ajuda a explorar os dados com mais clareza, permitindo perceber padrões que poderiam passar despercebidos em um mapa “poluído”. Além disso, as cores dos marcadores e os pop-ups com detalhes permitem analisar melhor a distribuição e as características dos lançamentos por região.

- Como exemplo, no print apresentado, o site CCAFS LC-40 possui 26 registros, sendo 19 marcados em vermelho e 7 em verde. Essa diferenciação visual acelera a comparação entre resultados: normalmente, vermelho indica falha e verde indica sucesso, oferecendo uma leitura imediata do desempenho do local de lançamento

Tarefa 3: Medir a distância do local de lançamento até pontos próximos (ex.: litoral)

```
coastline_lat = 28.56367
coastline_lon = -80.57163

# Example launch site coordinates (replace with actual launch site coordinates)
launch_site_lat = launch_sites_df.loc[launch_sites_df['Launch Site'] == 'CCAFS SLC-40', 'Lat'].values[0]
launch_site_lon = launch_sites_df.loc[launch_sites_df['Launch Site'] == 'CCAFS SLC-40', 'Long'].values[0]

# Calculate distance using the calculate_distance function
distance_coastline = calculate_distance(launch_site_lat, launch_site_lon, coastline_lat, coastline_lon)

print(f"Distance from launch site to closest coastline: {distance_coastline} km")
0.0s

Distance from launch site to closest coastline: 0.5097439631188213 km
```

Neste mapa, foi exibida a distância entre a base CCAFS SLC-40 e a costa mais próxima, estimada em cerca de 0,51 km. A linha (PolyLine) representa o caminho em linha reta, deixando evidente o quão perto a base está do litoral. Em geral, essa escolha geográfica é estratégica: lançar próximo ao mar ajuda a direcionar a rota inicial sobre áreas não povoadas e também favorece operações de segurança e recuperação, reduzindo a exposição de regiões habitadas a riscos.

Seção 4

Build a Dashboard with Plotly Dash

Contagem de sucessos de lançamento para todos os locais (gráfico de pizza)

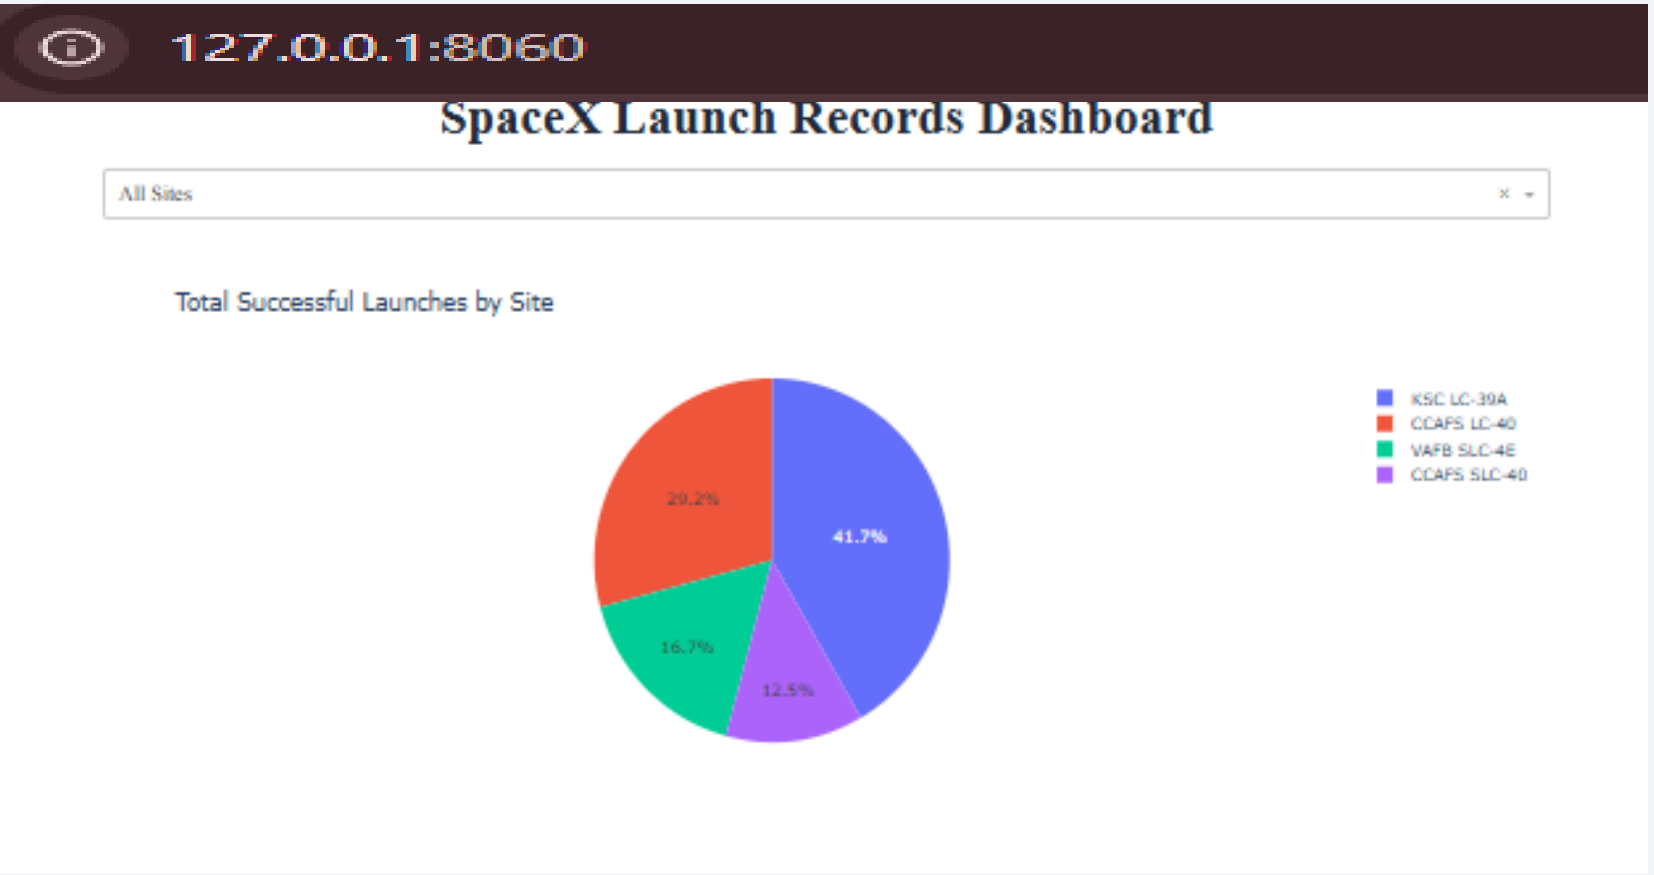

Destaques (Key Findings):

- CCAFS LC-40: 29,2%
- CCAFS SLC-40: 12,5%
- VAFB SLC-4E: 16,7%
- KSC LC-39A: 41,7%
- A base KSC LC-39A concentra a maior parcela de sucessos (41,7%), sugerindo maior consistência de desempenho e alta confiabilidade desse local nas operações de lançamento da SpaceX

Base com maior índice de sucesso (gráfico de pizza)

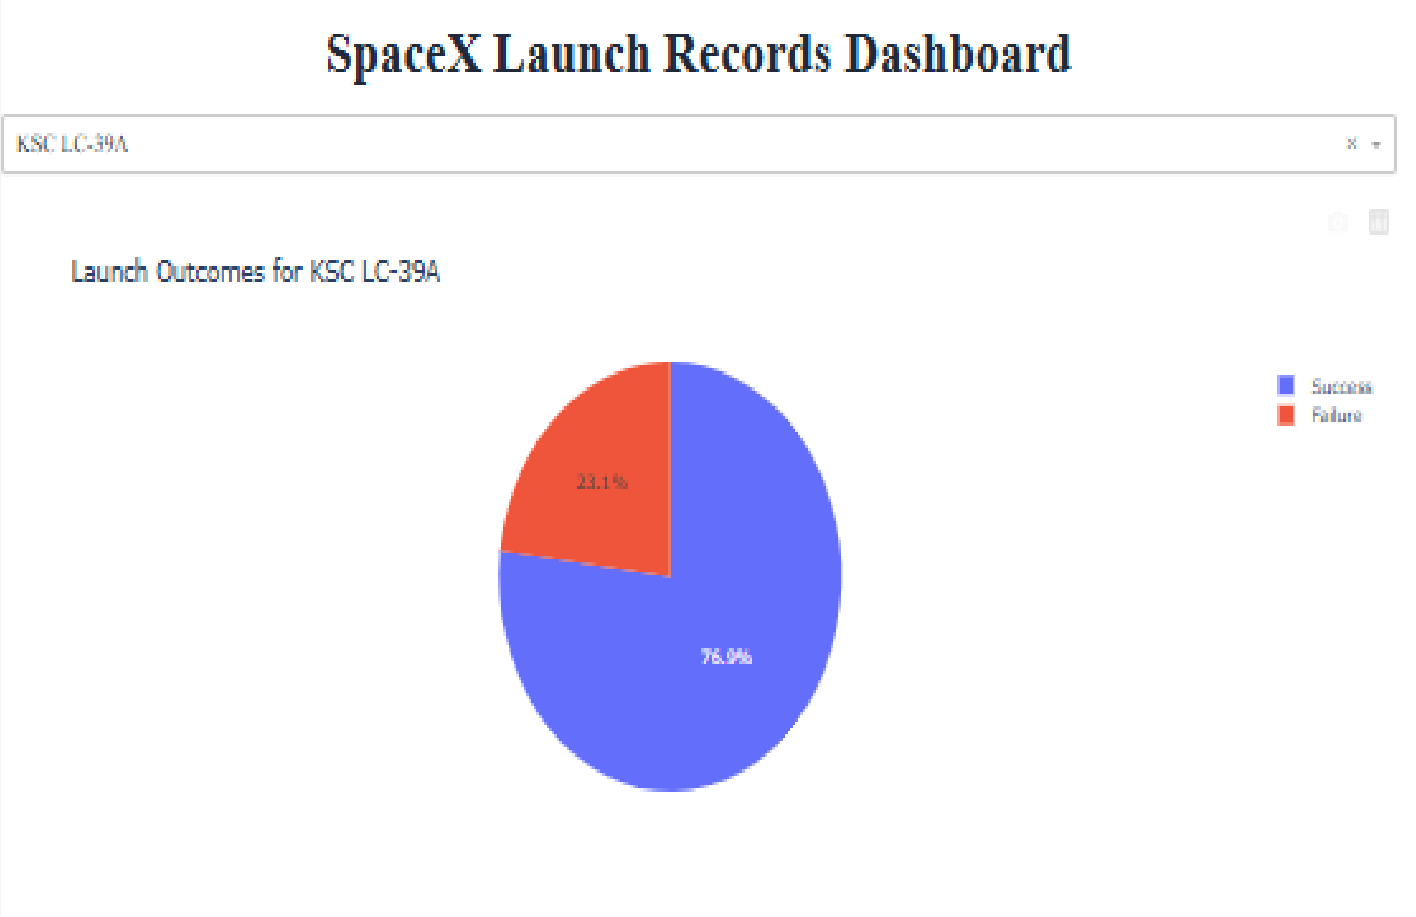

Destaques (Key Findings):

- O KSC LC-39A concentra uma proporção elevada de lançamentos bem-sucedidos, sugerindo um desempenho mais consistente e confiável.

- No KSC LC-39A:
  - Classe 1 (Sucesso): 76,9%
  - Classe 0 (Falha): 23,1%

- Com 76,9% de sucesso, o resultado indica que essa base apresenta alta eficiência operacional e forte confiabilidade nos lançamentos.

Resumo de insights do dashboard de lançamentos SpaceX

Taxa de sucesso por base:

- Entre as bases avaliadas, o KSC LC-39A lidera na participação de lançamentos bem-sucedidos, com 41,7%.
- Em taxa de sucesso por base, o KSC LC-39A também se destaca, com 76,9%.
- Já CCAFS LC-40, VAFB SLC-4E e CCAFS SLC-40 aparecem com percentuais menores, mostrando que o desempenho varia de acordo com a base de lançamento.

Comparação por versão do booster:

- O booster FT é o mais recorrente nos dados e mantém bons resultados mesmo com diferentes faixas de carga útil.
- O booster v1.0 tem amostragem menor, então precisa de mais dados/análises para conclusões mais firmes.
- De forma geral, não ficou evidente uma relação direta entre aumento de carga útil e queda na taxa de sucesso por versão de booster.

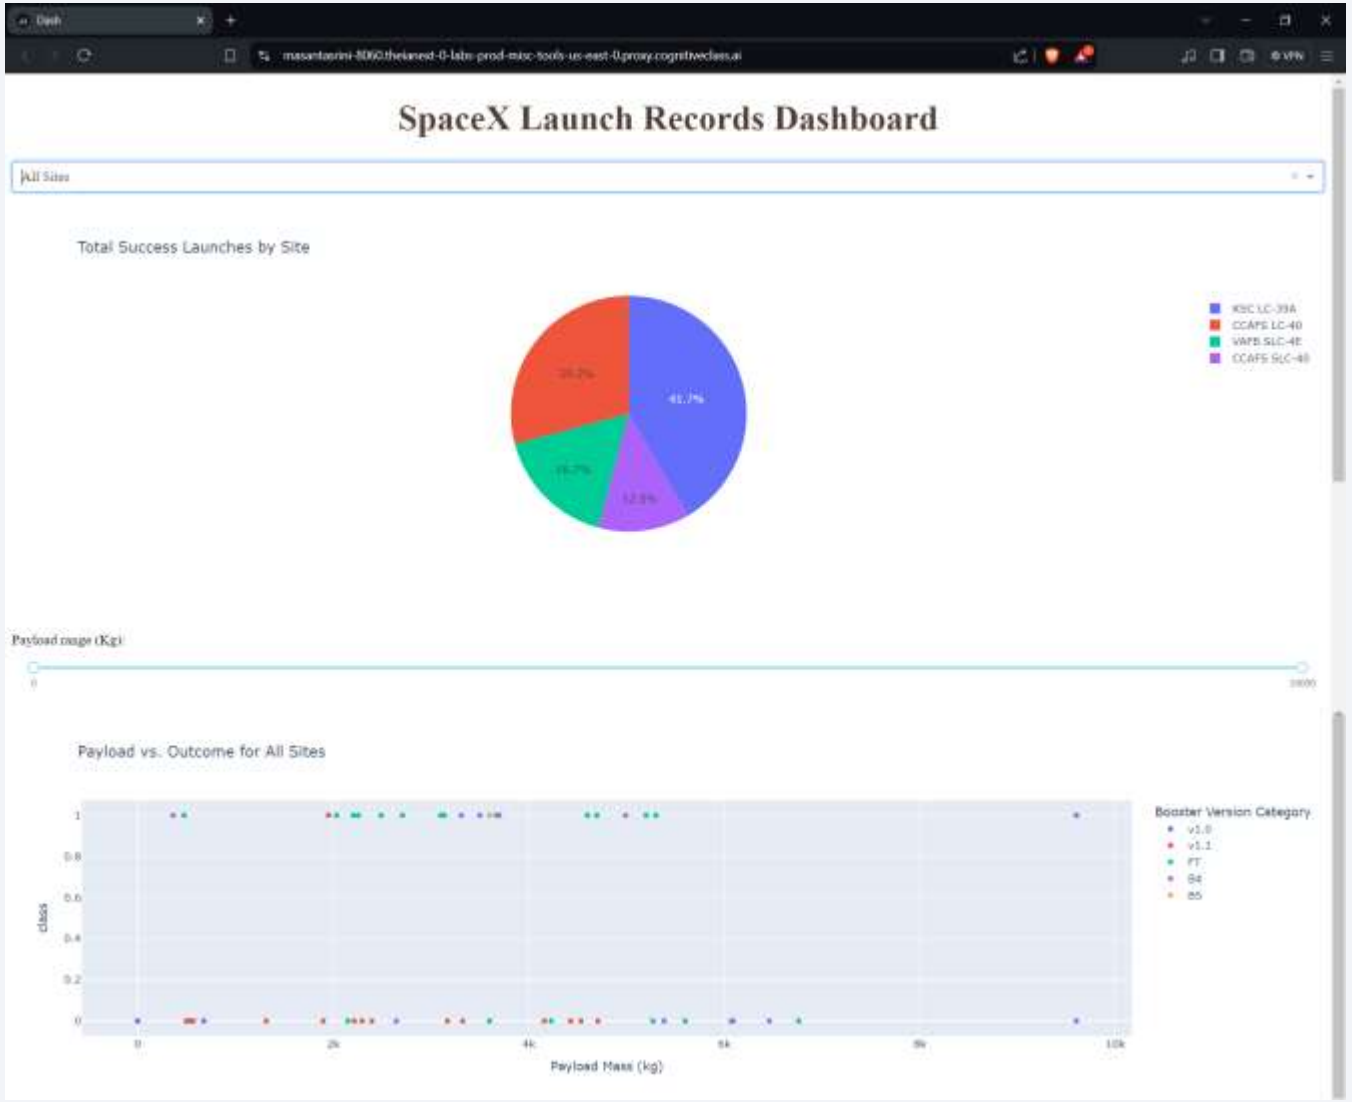

Seção 5

Predictive Analysis (Classification)

Desempenho (Acurácia) dos modelos

- Pelos resultados no conjunto de teste, a Árvore de Decisão foi o modelo com melhor desempenho, atingindo 0,9444 de acurácia. Em comparação, Regressão Logística, SVM e KNN ficaram em 0,8333, indicando que, para este dataset, a Árvore de Decisão se ajustou melhor e entregou previsões mais precisas.

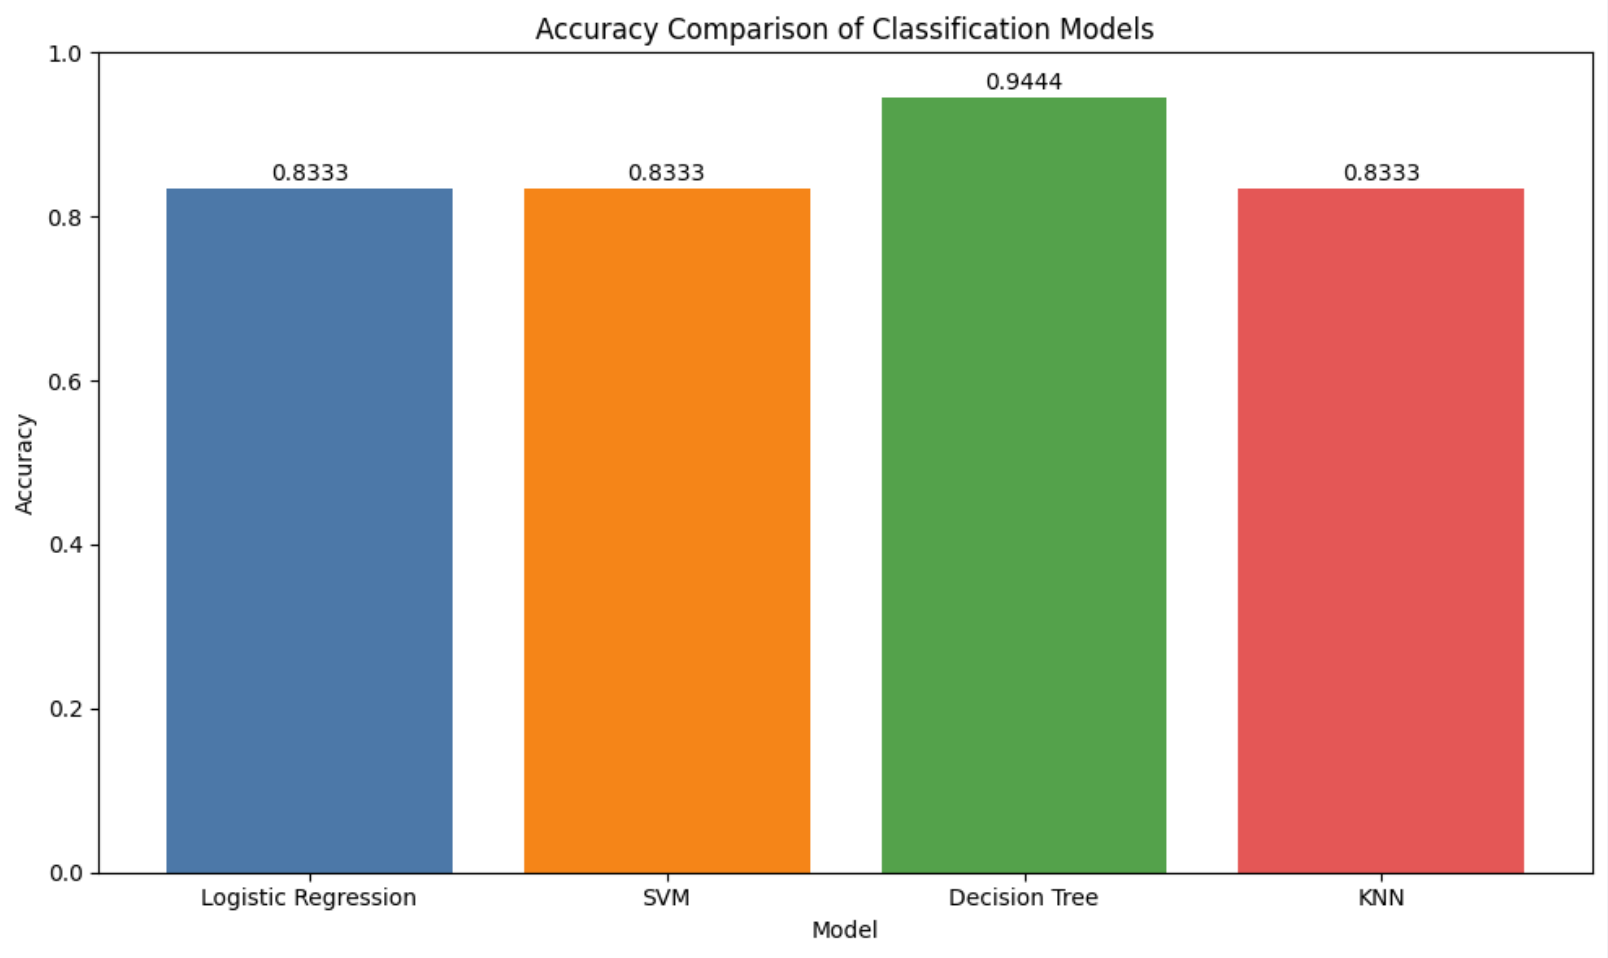

Análise da Matriz de Confusão

Explicação e insights

- **Acurácia elevada:** O classificador alcançou 94,44% de acerto, com boa quantidade de previsões corretas tanto para sucesso quanto para falha, indicando boa capacidade de generalização para o cenário analisado.

- **Zero falsos negativos:** Não ocorreram casos em que um pouso bem-sucedido foi previsto como falha, o que aumenta a confiança do modelo — especialmente em contextos onde errar um "sucesso real" pode afetar decisões operacionais.

- **Falso positivo em baixa quantidade:** Houve apenas 1 caso de falso positivo. Esse tipo de erro tende a ser menos problemático do que o oposto, já que leva a uma postura mais conservadora (preparar mais), o que é mais controlável na prática.

- **Resultado bem balanceado:** O modelo mantém um equilíbrio geral, com pequena tendência a prever sucesso. Em termos práticos, isso pode ser útil para planejamento e estimativas, desde que acompanhado de validações e monitoramento.

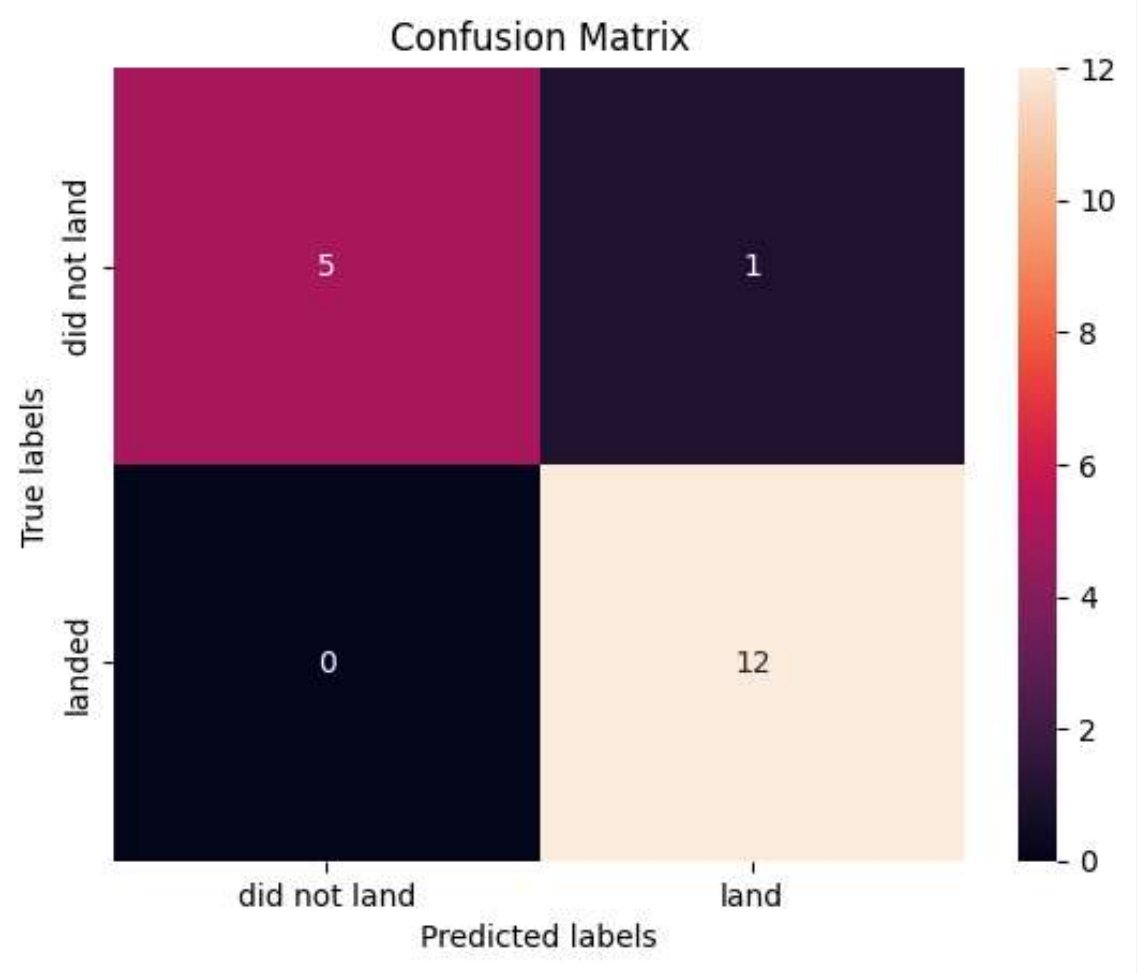

Conclusões

- Ponto 1: Entre os locais avaliados, o KSC LC-39A se destaca com a maior participação nos lançamentos bem-sucedidos (41,7%) e a maior taxa de sucesso por base (76,9%).

- Ponto 2: Pelos resultados do scatter plot, o booster FT mantém desempenho alto em diferentes faixas de carga útil, indicando maior estabilidade e confiabilidade quando comparado a outras versões. Assim, priorizar essa versão em missões futuras pode aumentar a probabilidade de sucesso.

- Ponto 3: Os dados não evidenciaram uma relação direta entre aumento de carga útil e queda no sucesso. Isso reforça que o desfecho do lançamento parece ser mais influenciado por outros fatores, como o local de lançamento e a versão do booster, do que apenas pela massa transportada.

Conclusões

- Ponto 4: O uso de mapas e dashboards interativos com Folium e Plotly Dash trouxe uma leitura mais clara dos dados, destacando padrões de localização e aspectos operacionais dos lançamentos. Com isso, a análise ficou mais explorável e objetiva, apoiando decisões com base em evidências visuais.

- Em resumo, a combinação de modelagem preditiva com visualizações interativas ajudou a identificar os principais fatores associados ao desempenho dos lançamentos e ainda criou uma base sólida para análises futuras. Esses resultados podem orientar ajustes em estratégias operacionais e fortalecer iniciativas ligadas à evolução e confiabilidade de foguetes reutilizáveis.

Thank you!